

XJTU

硕士学位论文

基于 IMU 和 WiFi 的人体活动识别与姿态重构方法研究

学位申请人：邢立豹

指导教师：王飞 副教授

类别（领域）：工程硕士（软件工程）

2026 年 05 月

Research on Human Activity Recognition and Pose Reconstruction Methods Based on IMU and WiFi

A thesis submitted to
Xi'an Jiaotong University
in partial fulfillment of the requirements
for the degree of
Master of Engineering

By
Libao Xing
Supervisor: Associate Prof. Fei Wang
Master of Engineering (Software Engineering)
May 2026

硕士学位论文答辩委员会

基于 IMU 和 WiFi 的人体活动识别与姿态重构方法研究

答辩人：邢立豹

答辩委员会委员：

西安交通大学教授：朱利 (注：主席)

西安交通大学副教授：徐亦飞

答辩时间：2026 年 05 月 06 日

答辩地点：西安交通大学创新港鸿理楼 4-3202

摘 要

基于 Wi-Fi 信道状态信息 (Channel State Information, CSI) 的室内动作识别能够利用人体运动引起的信道变化实现非视觉感知, 在智能家居、健康监护和环境感知等场景中具有应用价值。与固定类别条件下的离线识别不同, 实际系统中的动作类别往往会随应用需求逐步增加, 同时旧类数据难以长期完整保留, 新类样本数量也可能不足。传统依赖全量样本集中训练的方法难以适应此类持续更新需求。针对上述问题, 本文围绕 Wi-Fi CSI 室内动作识别中的类别持续扩展问题, 分别研究新增类样本相对充足的类增量学习和新增类样本极少的少样本类增量学习两类场景。

针对类增量学习场景, 本文提出一种回放—扩展—巩固框架。该方法通过记忆库重放保留旧类代表样本, 利用冻结骨干与分类器扩展实现新类别接入, 并结合教师—学生结构与双边知识蒸馏完成新旧类知识巩固, 以缓解灾难性遗忘和新旧类分布失衡。针对少样本类增量学习场景, 本文提出一种基于时序增强与图注意力的学习方法。该方法利用多尺度时序编码和时序注意力融合增强 CSI 动作时序表征, 在增量阶段通过增强图注意力网络建模类别原型关系, 并结合双分类器架构缓解新旧类偏置和类别级过拟合。

在 XRF 与 WiAR 两个公开 Wi-Fi 动作识别数据集上的实验结果表明, 所提类增量学习方法在多阶段类别扩展过程中具有较好的增量稳定性。其中, 在 XRF 数据集上末次增量阶段准确率达到 73.57%; 在 WiAR-16 类增量设置下, 平均准确率达到 77.33%, 末次阶段准确率达到 64.58%。所提少样本类增量学习方法在 XRF 的 5-way 1-shot 设定下末次增量会话准确率达到 74.24%, 平均准确率达到 78.48%; 在 WiAR 数据集上平均准确率为 75.30%, 末次会话准确率为 61.81%, 整体优于 CEC、FACT、C-FSCIL、DyCR 等对比方法。综上, 本文从类增量学习和少样本类增量学习两个层面提出面向 Wi-Fi CSI 动作识别的持续学习方法, 为动态场景下 Wi-Fi 感知系统的持续更新提供了可行思路。

关 键 词: Wi-Fi CSI; 室内动作识别; 持续学习; 类增量学习; 少样本类增量学习

论文类型: 应用研究

ABSTRACT

Indoor action recognition based on Wi-Fi Channel State Information (CSI) exploits channel variations caused by human motion to enable non-visual sensing, and has application value in smart homes, health monitoring, and environmental perception. Unlike offline recognition under a fixed label set, real-world systems often encounter progressively expanding action categories, incomplete retention of old-class data, and insufficient samples for newly introduced classes. Conventional training methods based on full static datasets are therefore difficult to adapt to continual update requirements. To address these issues, this thesis focuses on continuous category expansion in Wi-Fi CSI-based indoor action recognition and investigates two scenarios: class-incremental learning with relatively sufficient new-class samples and few-shot class-incremental learning with extremely limited new-class samples.

For the class-incremental learning scenario, this thesis proposes a Replay-Expansion-Consolidation framework. Representative old-class samples are preserved through memory replay, new categories are incorporated by combining backbone freezing with classifier expansion, and old and new knowledge is consolidated through a teacher-student structure with bilateral knowledge distillation. This design alleviates catastrophic forgetting and the distribution imbalance between old and new classes. For the few-shot class-incremental learning scenario, this thesis proposes a learning method based on temporal enhancement and graph attention. Multi-scale temporal encoding and temporal attention fusion are used to enhance CSI temporal representations, an enhanced graph attention network is employed to model relations among class prototypes during incremental sessions, and a dual-classifier architecture is adopted to reduce old-new class bias and class-level overfitting.

Experiments on the XRF and WiAR public Wi-Fi action recognition datasets show that the proposed class-incremental learning method maintains favorable stability during multi-stage category expansion. It achieves 73.57% accuracy at the final incremental stage on XRF; under the WiAR-16 class-incremental protocol, it obtains an average accuracy of 77.33% and a final-stage accuracy of 64.58%. Under the 5-way 1-shot setting on XRF, the proposed few-shot class-incremental learning method achieves 74.24% accuracy at the final session and an average accuracy of 78.48%. On WiAR, it obtains an average accuracy of 75.30% and a final-session accuracy of 61.81%, outperforming CEC, FACT, C-FSCIL, DyCR, and other baselines overall. In summary, this thesis proposes continual learning methods for Wi-Fi CSI-based action recognition from the perspectives of class-incremental learning and few-shot class-incremental learning, providing a feasible solution for the continual updating of Wi-Fi sensing

systems in dynamic scenarios.

KEY WORDS: Wi-Fi CSI; Indoor action recognition; Continual learning; Class-incremental learning; Few-shot class-Incremental learning

TYPE OF THESIS: Application Research

目 录

声明

CONTENTS

Declarations

1 绪论

1.1 选题意义及应用背景

随着无线网络基础设施在家庭、办公与公共空间中的持续普及,利用现有 Wi-Fi 设备开展环境感知和行为识别逐渐成为室内智能感知的重要实现方式。相较于依赖摄像头或可穿戴设备的方案,基于 Wi-Fi 的感知方法无需额外贴身部署,且不直接采集可见图像信息,因此在部署便捷性、使用接受度以及隐私敏感场景适用性方面具有一定优势。在这一背景下,围绕商用无线信号开展室内动作识别研究,已成为无线感知领域值得关注的研究方向。随着 Wi-Fi 在家庭、办公与公共场所的广泛部署^{ma2019wifi,oughton2021wifi5g}以及物联网终端数量的持续增长^{zeinab2017iot},利用现有通信基础设施进行无线感知,已成为低部署成本、易扩展的实现路径之一。

在 Wi-Fi 感知中,人体移动、遮挡和肢体动作会改变室内多径传播结构,并进一步反映到无线信道响应的时间变化上。信道状态信息相比接收信号强度指标能够提供更丰富的细粒度描述,不仅包含不同子载波上的响应差异,也能够表征多天线链路上的传播变化,因此更适合用于刻画复杂动作造成的动态扰动^{ma2019wifi}。围绕 CSI 的室内动作识别研究已经从早期依赖人工设计特征和传统分类器的方法,逐步发展到利用深度模型自动学习时空表征的方法,识别性能与模型表达能力均得到提升。但在类别不断扩展、旧数据难以重复获得以及标注样本受限等实际条件下,现有方法仍难以直接满足长期更新需求。

与实验室条件下预先给定类别集合的识别任务不同,真实场景中的动作类别往往具有动态扩展特征。系统在初始部署阶段通常只覆盖少量核心动作,后续会随着监测目标变化逐步引入新的行为类型。如果每次类别扩展都重新采集全部历史类别与新增类别数据,并在统一数据集上重新训练模型,不仅会带来较高的时间与计算开销,也会显著增加数据组织与标注成本。对于需要持续运行的 Wi-Fi 感知系统而言,这种更新方式缺乏现实可操作性。因此,使模型能够在保留既有识别能力的同时逐步吸收新类别知识,是该类系统走向长期应用必须解决的关键问题。

此外,Wi-Fi 感知数据的采集过程本身也受到较多条件限制。与图像数据相比,CSI 数据采集通常依赖稳定的收发设备布置、特定场景下的重复录制以及后续预处理与人工标注,整个流程更容易受到场地条件、设备状态和人员配合程度的影响。当识别类别逐步增加时,重新组织完整数据采集往往需要较高的人力成本和较长的实验周期,这使得依赖全量数据反复重训的方式在很多场景中并不现实。因此,从固定类别条件下的离线识别转向面向类别扩展的持续学习,是 Wi-Fi 室内动作识别进一步走向长期应用过程中需要解决的重要问题。

基于 CSI 的人类活动识别 (Human Activity Recognition, HAR) 已采用长短期记忆

(LSTM)、循环神经网络(RNN)与卷积神经网络(CNN)等深度模型从原始或预处理后的 CSI 数据中提取特征并完成分类^{ma2019wifi}。然而,这类方法通常假定训练前可获取全部类别数据,模型训练完成后若要识别新增动作类别,往往需要从头重训,带来较长训练时间与较高存储开销。现实场景中,用户行为、环境布局与活动类型会随时间变化,数据往往以流式方式到来,模型需能持续适应新类别,而传统批量学习难以满足流式数据下的更新需求。类增量学习关注的是:当新类别按阶段持续到达时,模型如何在主要利用当前阶段数据完成更新的同时,继续保持对历史类别的统一识别能力。与一次性获得全部类别数据的离线训练不同,这类任务更强调模型在持续更新过程中的知识保留与新类吸收能力;其核心挑战在于灾难性遗忘——在固定容量网络中直接优化新类会覆盖旧类表征,导致旧类识别性能急剧下降^{zhou2024cil}。这对应于神经网络中的稳定性—可塑性困境:模型若过于稳定则难以充分学习新类别,若过于可塑则易遗忘旧知识。研究面向 Wi-Fi CSI 的类增量学习方法,有助于在保持对旧动作记忆的同时吸收新动作知识,从而提升室内活动识别系统在动态环境中的适应性。

在此基础上,少样本类增量学习(Few-Shot Class-Incremental Learning, FSCIL)进一步引入了新类监督极度受限的条件,即每个新增类别通常只提供 1 至 5 个标注样本;模型因此需要在样本极少与类别持续扩展同时存在的情况下完成更新,其难点明显高于常规类增量学习^{tian2024fscilsurvey}。现实应用中,CSI 数据采集与标注成本较高:高精度 Wi-Fi 接入点与专用采集设备需专业人员安装调试,CSI 数据通常具有规模大、存储开销高和标注依赖人工等特点,而标注质量又会直接影响后续模型效果。正因如此,在健康监护、工业巡检等成本敏感场景中,提高有限样本的利用效率、减少对大规模标注数据的依赖,具有较强现实意义。与传统视觉任务相比,Wi-Fi CSI 场景下的少样本增量问题还具有更强的特殊性。一方面,CSI 本质上是对无线信道传播状态的时序观测结果,其特征不仅与人体动作本身有关,还与空间布局、遮挡关系、多径传播结构以及设备布置方式密切相关;同一动作在不同环境、不同用户甚至不同时间段下都可能表现出较大差异。另一方面,一些细粒度动作在信号层面具有较强相似性,例如幅度接近的肢体摆动、节奏相近的连续动作等,容易在类别持续扩展时带来新旧类别之间的混淆。因此,在 Wi-Fi CSI 条件下开展少样本类增量学习,模型不仅需要在极少样本下形成对新类别的有效表征,还需要尽可能保持旧类别判别边界的稳定性,其难度高于一般的固定类别少样本识别任务。

从应用角度看,这种新增类别样本有限但类别仍会继续增加的情况在无线感知任务中并不少见。在康复监护、养老看护和工业巡检等场景中,新增动作通常具有较强的场景依赖性和阶段性,采集者难以像构建离线数据集那样为每一个新类别准备大量标注样本。若模型不能在少样本条件下较快完成新类学习,系统的后续扩展将受到限制;若在学习新类的过程中旧类性能明显下降,又会影响系统长期运行的稳定性。因此,研究面向 Wi-Fi CSI 的少样本类增量学习,不仅有助于提高模型对新类别的适应能力,也有助于提升系统在长期应用中的可扩展性。

例如，老年人护理场景下新增康复动作类别时，往往难以获取大量标注样本；智能家居中用户偏好变更带来的新动作类型，也需模型在少量样本下完成适配。因此，本文关注的不是固定类别集下的离线识别性能提升，而是 Wi-Fi CSI 室内动作识别在类别持续扩展条件下的持续学习能力；进一步地，本文分别讨论新增类样本相对充足和极少两类典型场景。本论文围绕上述两个方向，分别提出面向 Wi-Fi CSI 的类增量学习框架与少样本类增量学习方案，并在 XRF 与 WiAR 等公开数据集上进行验证。

1.2 国内外研究现状分析

1.2.1 面向 Wi-Fi 信号室内动作识别任务发展现状

面向室内场景的人类活动识别研究经历了由可穿戴传感、视觉感知到无线感知不断拓展的发展过程，其中基于 Wi-Fi 信号的动作识别因能够复用现有通信基础设施而受到持续关注。该方向的核心思路在于，将人体活动对无线传播路径造成的扰动转化为可建模的信号变化，再通过特征分析或模式学习实现行为判别。随着商用 Wi-Fi 设备可获取更稳定的信道信息，研究重点也逐步从早期的粗粒度状态检测转向更细粒度的动作识别与行为理解，应用场景则进一步延伸到家庭护理、健康监测、安防感知和智能环境交互等领域^{ma2019wifi}。

从技术演进看，早期 Wi-Fi 感知研究更多围绕 RSSI 展开，相关方法主要服务于室内定位或粗粒度状态感知。微软在 2000 年推出的 RADAR 系统^{bahl2000radar}通过测量接收信号强度实现室内定位，是该领域的先驱性工作；随后 HORUS 系统^{youssef2004horus}与 Bose 等的研究^{bose2007pathloss}同样采用 RSSI 进行定位建模。由于 RSSI 仅反映接收功率变化，其对复杂多径环境下细微动作差异的刻画能力有限，难以支撑更精细的行为识别任务。随着研究逐步转向 CSI，利用商用设备获取更高分辨率的信道响应成为可能，人体动作对传播路径造成的扰动也因此能够以更细致的形式被记录下来。以 WiHear、E-eyes 和 WiFall 为代表的一批工作表明^{wang2014wihear,wang2014eeyes,wang2016wifall}，基于 CSI 的方法已经能够支持语音、日常活动和跌倒检测等多种任务，为后续室内动作识别研究奠定了基础。早期工作多依赖传统的时频域分析与手工特征设计，随着深度学习技术的成熟，研究者逐步转向端到端学习范式，使得基于 Wi-Fi 的室内活动识别在精度与泛化能力上得到提升。

现有基于 Wi-Fi CSI 的室内动作识别方法大体可以从表征方式上分为经验特征驱动方法、传播机理建模方法和深度表征学习方法。第一类方法通常对 CSI 进行滤波、编码或统计变换，并利用构造得到的分布特征完成匹配或分类，代表性思路是将特定动作对应的信号模式视为可检索的“指纹”；这类方法实现相对直接，但对环境变化较为敏感^{wang2014eeyes}。第二类方法尝试从人体运动与信道扰动之间的关系出发建立描述模型，例如分析 CSI 变化速度、活动过程与动作类别之间的对应关系，从而增强识别的可解释性^{wang2015csiactivity}。第三类方法则借助卷积网络等深度模型，直接从原始或预处理后的 CSI 数据中学习判别特征，在复杂场景中通常表现出更强的表征能

力^{zeng2014cnn,cho2018divide}。总体来看,不同方法在实现成本、鲁棒性与精度之间各有取舍,但大多数研究仍建立在固定类别集和离线训练条件之上,对类别逐步扩展时的持续更新问题关注不足。

总体来看,现有研究已经从不同角度验证了商用 Wi-Fi 设备用于室内动作识别的可实施性,也说明该方向在方法设计与任务拓展上具有较丰富的发展路径。此外,鲁勇等对基于 Wi-Fi 信号的人体行为感知技术进行了系统梳理,从定位、检测、识别等多个任务维度总结了 Wi-Fi 感知的发展脉络与关键挑战,进一步说明了 Wi-Fi 感知在人类活动识别中的研究价值^{luyong2019wifiharreview}。不过, Wi-Fi 室内动作识别在实际部署中仍受到多方面约束,例如环境变化、设备差异、连续数据到达方式以及存储资源限制等因素,都会削弱模型在跨场景条件下的稳定性与泛化表现^{ma2019wifi}。XRF55^{wang2024xrf55}等数据集在类别数量(55类)与样本规模上为增量学习研究提供了数据基础。该数据集涵盖人一物交互、人一人交互、健身、身体运动与人一机交互等五大类室内活动,从日常动作(如走路、坐下)到复杂交互(如转呼啦圈、演奏乐器)均有覆盖,既能反映现实场景的多样性,也满足增量学习对类别数与数据量的要求。然而,现有工作多面向固定类别集的离线训练,对类别持续扩展条件下的模型更新讨论不足。当类别集合随业务需求扩展时,往往缺乏系统化的增量更新方案;而面向 Wi-Fi CSI 的少样本类增量学习研究更为稀缺,既需应对 CSI 信号的高维与时变特性,又需在极少量样本下维持旧类判别能力。在此背景下,将类增量学习与少样本类增量学习的理论与方法引入面向 Wi-Fi CSI 的室内动作识别任务,有助于弥合现有工作在类别动态扩展场景中的不足。

1.2.2 面向 Wi-Fi 感知的持续学习模式研究现状

将持续学习引入面向 Wi-Fi 的室内活动识别,需要同时应对两方面挑战:一方面,人类活动的多样性与环境的动态性要求系统能够实时适应新出现的活动类型,并保持对已学活动的识别能力;另一方面, Wi-Fi 信号对环境因素敏感(如房间布局、物体摆放、人员移动等),且 CSI 数据的采集与标注成本较高,使得在新类别出现时获取大量标注样本往往不现实^{ma2019wifi}。

对于持续到达的动态数据,传统模型往往难以同时兼顾新知识吸收与旧知识保持,学习新任务后旧任务性能明显退化的现象较为常见。这种灾难性遗忘会直接限制 Wi-Fi 感知系统在长期运行中的持续识别能力。从更一般的机器学习视角看,类别增量学习要求模型在不断接收新类别数据的同时保持对旧类别的判别能力,灾难性遗忘、类别不平衡与评价协议差异是该方向的核心问题。朱飞等对类别增量学习的任务设定、代表方法与性能评价进行了系统总结,为理解本文所研究的 Wi-Fi CSI 场景下类增量学习问题提供了通用理论参照^{zhufei2023cilreview}。针对 Wi-Fi 场景下的类增量学习,已有研究开始尝试将通用持续学习机制迁移到无线感知任务中。例如, WiCAR^{licar2024wicar}通过结合记忆回放、知识蒸馏和类别平衡策略,缓解增量训练中的遗忘与样本失衡问题; WiCI-HAR^{ding2023wicihar}则采用分阶段训练方式,在增量更新时减弱特征提取器与分类器之间的相互干扰,并借助注意力改进网络结构和多损失约束提升对新类别样本的利用效果。

这些工作表明，面向 Wi-Fi 感知的类增量学习已经具备初步可行性，但现有实验通常仍停留在类别规模较小、增量轮次有限的设置下，对复杂动作区分能力和长期扩展稳定性的讨论仍然不够充分。此外，上述方法均假设每个增量任务可访问充足的新类样本，而在健康监护、工业巡检等场景中，新增动作类别往往难以在短期内采集大量标注数据，这使得少样本条件下的类增量学习成为亟待探索的方向。

在新增类别样本受限的情形下，少样本学习为 Wi-Fi 感知提供了另一条值得关注的技术路径。相关研究通常通过度量学习、图结构建模或注意力机制提高模型对少量支持样本的利用效率。例如，有工作利用图卷积与注意力模块共同建模动作样本之间的关联关系，以增强跨场景条件下的识别能力^{zhang2021csigdam}；也有研究将原始 CSI 映射到更具判别性的嵌入空间，并结合基于距离的预测策略完成低样本条件下的活动识别^{ding2021oneshot}。这类方法说明，Wi-Fi CSI 在样本有限时仍具有可学习的判别结构，但它们大多面向固定类别体系下的快速适配，并未进一步讨论类别持续增加时旧类保持与新类学习之间的矛盾。因此，少样本学习能够为 Wi-Fi 感知中的数据受限问题提供支持，但尚不能直接替代少样本类增量学习研究。在实际部署条件下，反复组织大规模 CSI 采集并据此重新训练模型往往代价过高，因此仅依赖完全重训的思路缺乏现实操作性。相比之下，面向 Wi-Fi 感知的少样本类增量学习仍处于探索阶段，其应用潜力还有待进一步挖掘。相较于计算机视觉领域已在 CIFAR-100、miniImageNet 等基准上形成较为成熟的 FSCIL 方法体系，面向 Wi-Fi CSI 的少样本类增量学习在任务定义、评价协议与算法适配等方面仍存在研究空白。具体而言，当前的研究缺口可归纳为三点：（1）现有 Wi-Fi CIL 方法多假设每个增量任务可访问充足的新类样本；（2）现有 Wi-Fi 少样本学习多不考虑类别持续扩展的场景；（3）现有视觉领域的 FSCIL 方法难以直接迁移到 Wi-Fi CSI 时序模态，需针对 CSI 时序特性开展专门设计。综上，现有研究尚未同时覆盖 Wi-Fi 室内动作识别中类别持续扩展与新增类样本稀缺这两类典型情形。基于上述问题，本文将研究重点放在 Wi-Fi CSI 条件下的类增量学习与少样本类增量学习两类任务上，并结合 CSI 的时序特点设计对应方法。

基于上述分析可知，面向 Wi-Fi CSI 室内动作识别的持续学习研究目前仍处于不断探索阶段，在任务设定与方法设计上尚未形成较为统一的技术路线。现有工作一方面更多围绕新增类样本相对充足的类增量学习情形展开，重点在于缓解灾难性遗忘和新旧类别不平衡；另一方面，与少样本相关的研究又主要集中在固定类别条件下的快速识别，对类别集合持续扩展时模型表征稳定性与泛化能力之间的平衡考虑不足。也就是说，Wi-Fi 感知中的类增量学习和少样本类增量学习虽然都服务于模型的持续更新，但二者所面对的约束条件和关键问题并不相同，需要分别研究。

基于此，本文在后续研究中将这两类问题分开讨论，并按照由一般到困难的顺序展开：首先面向新增类样本相对充足的情形，研究如何通过样本重放、分类器扩展和知识巩固等方式缓解灾难性遗忘，构建适用于 Wi-Fi CSI 的类增量学习方法；随后进一步面向新增类样本极少的情形，研究如何在极少监督条件下兼顾新类学习与旧类保持。

这样安排的原因在于，两类问题的约束条件并不相同。先讨论新增类样本相对充足的情形，再进一步讨论极少样本条件下的增量学习，更便于说明本文方法是如何逐步展开的。

1.3 论文的主要研究内容

围绕上述两类持续更新场景，本文开展了对应的方法设计与实验研究，主要工作如下：

1) 针对类增量学习场景，提出回放—扩展—巩固的学习框架，通过类均值选样记忆回放、冻结骨干下的分类器扩展以及双边知识蒸馏巩固缓解灾难性遗忘。本文将重放、扩展与巩固组织为闭环流程，在 XRF 与 WiAR 上验证表明，该流程在多种类别规模与 CSI 数据分布下均具较好增量稳定性；XRF 上末阶段（Session 4）准确率达 73.57%，WiAR-16 上末阶段与平均准确率分别为 64.58%、77.33%，均优于文中所列主要对比方法（见第三章）。

2) 针对少样本类增量学习场景，提出基于时序增强与图注意力的学习方案，通过多尺度时序编码、时序注意力融合、增强图注意力网络与双分类器架构，提升少样本条件下的新类适应能力与旧类保持能力。在「增量侧每类仅极少标注、且主实验不依赖旧类原始数据回放」的条件下，模型除灾难性遗忘外，还需应对原型估计不稳、新旧类 logits 偏置与类别级过拟合等相互耦合的问题；因此方法设计需同时强化 CSI 时序表征、类别间关系建模与分类器融合。在 XRF 5-way 1-shot 与 WiAR16 设定下的实验表明，末会话准确率、PD 与 AA 等指标优于多种对照（详见第四章），并引入 DyCR 等近年方法作为对比。

1.4 论文的组织结构

全文共分为五章，整体结构如图 ?? 所示，各章主要内容安排如下。




图 1-1 本文组织结构与研究内容示意

第一章绪论。介绍 Wi-Fi CSI 室内动作识别的研究背景与应用意义，梳理无线感知与持续学习相关研究现状，并说明本文研究问题、主要内容与章节安排。

第二章相关理论和知识背景。介绍 Wi-Fi CSI 感知原理、类增量学习、少样本学习和少样本类增量学习等基础理论，为后续方法设计提供支撑。

第三章面向 Wi-Fi 信号动作识别的类增量学习方法研究。针对新增类样本相对充足的类增量学习场景，提出回放—扩展—巩固框架，并通过对比实验与消融实验验证各模块作用。

第四章面向 Wi-Fi 信号动作识别的少样本类增量学习方法研究。针对新增类样本极少的少样本类增量学习场景，提出基于时序增强与图注意力的学习方案，并在不同数据集设置下验证其有效性。

第五章结论与展望。总结全文主要研究结论，并结合方法局限说明后续可进一步完善的方向。

2 相关理论和知识背景

2.1 基于 Wi-Fi 的 CSI 信号的人类活动识别原理

如第一章所述，基于 Wi-Fi 信道状态信息（Channel State Information, CSI）的人类活动识别通过分析人体活动对无线信号传播的影响实现动作推断。本节从信号层面阐述 CSI 的物理含义与数据表示，为第三、四章的模型输入提供技术背景。图 ?? 给出了基于 Wi-Fi CSI 信号的人类活动识别系统通用流程，其核心是建立人体行为与 CSI 信号变化之间的映射关系。




图 2-1 基于 Wi-Fi CSI 的人类活动识别系统通用流程

CSI 是描述无线信道传播特性的核心参量，刻画了信号在发射端与接收端之间沿各条路径传播时的幅度衰减与相位偏移。在室内环境中，无线信号经反射、折射、散射、衍射等多径效应到达接收端，各路径对最终接收信号产生不同的幅度与相位贡献，CSI 正是对这些变化的精细刻画^{ma2019wifi}。因此，当人体进入传播区域时，其移动、遮挡、反射等会改变多径结构，进而引起 CSI 的时变特征，为活动识别提供了物理依据。

在遵循 IEEE 802.11 标准的现代 Wi-Fi 系统中，物理层通过多输入多输出（Multiple-Input Multiple-Output, MIMO）与正交频分复用（Orthogonal Frequency-Division Multiplexing, OFDM）协同工作。MIMO 在收发两端配置多天线，利用多径效应提升吞吐量；OFDM 将宽带信号划分为若干窄带子载波，各子载波在频域正交、互不干扰。对于 MIMO-OFDM 信道，每个子载波上每对收发天线对应一个 CSI 复数响应。信道频响（Channel Frequency Response, CFR）可表示为

$$H(f; t) = \sum_{n=1}^N a_n(t) e^{-j2\pi f \tau_n(t)} \quad (2-1)$$

式中： $H(f; t)$ ——频率 f 、时刻 t 处的信道频响； $\tau_n(t)$ ——第 n 条路径传播时延（ $a_n(t)$ 为对应幅度衰减）。

式 (??) 将各路径的时变增益与时延对频域响应的线性叠加关系形式化，用于刻画 CSI 在不同频率与时隙下的复数值；CSI 的幅度 $|H|$ 与相位 $\angle H$ 受发射端、接收端及环境中物体位移与运动影响，从而将环境变化蕴含于信道特性之中。

对于具有 M 根发射天线、 N 根接收天线、 K 个子载波的 MIMO-OFDM 系统，单次测量的 CSI 可表示为三维复数矩阵 $H \in \mathbb{C}^{N \times M \times K}$ ，分别对应空间维度（收发天线对）与频域维度（子载波）。在时间维度上对 CSI 进行连续采样，可得到四维 CSI 张量，在时、频、空三个域内刻画信道随人体活动产生的变化。CSI 数据在子载波维与数据包（或时间戳）维上组织，每个时间戳对应一个 $N_T \times N_R \times N_{\text{sub}}$ 的矩阵，其中 N_T 、 N_R 、 N_{sub} 分别为发射天线数、接收天线数与子载波数。

在 IEEE 802.11n/ac 协议栈中，CSI 的获取通常依赖物理层前导结构。发射端在每帧前导内插入长训练域（Long Training Field, LTF）或高吞吐量长训练域（HT-LTF），接收端根据已知的发送序列与接收信号估计各子载波的信道响应，进而得到 CSI 矩阵。商用网卡（如 Intel 5300）通过修改驱动或固件可导出每根天线、每个子载波上的 CSI 至用户态，使得基于 CSI 的感知应用得以在通用硬件上实现，无需额外传感器。原始 CSI 数据常含有噪声、载波间干扰及硬件偏差，因此在特征提取前需进行预处理：常见步骤包括异常值剔除、线性趋势去除、滑动平均或滤波以抑制高频噪声，以及必要时对幅度与相位进行标准化或归一化，为后续特征提取与分类奠定基础。

相较接收信号强度指示（Received Signal Strength Indication, RSSI），CSI 具有更高的分辨能力。RSSI 仅提供单一标量功率值，而 CSI 在多个子载波与天线对上提供复数响应，能更细致地反映多径结构，因而更适合细粒度感知任务。在室内活动识别中，CSI 幅度的时域变化可区分不同人体、动作与手势，相位的空频域变化可用于定位与呼吸估计等^{ma2019wifi}。信道冲激响应 $h(\tau)$ 在频域的另一种表述形式为

$$h(\tau) = \sum_{l=1}^L \alpha_l e^{j\varphi_l} \delta(\tau - \tau_l) \quad (2-2)$$

式中： $h(\tau)$ ——时延 τ 处的信道冲激响应； $\delta(\cdot)$ ——狄拉克 δ 函数。

式 (??) 将信道冲激响应表示为多径抽头的加权脉冲叠加，便于从时延域理解 CSI 与人体活动对路径时延、衰减的调制作用。

按输出类型，基于 CSI 的 Wi-Fi 感知应用可分为三类：检测（二分类，如人体存在检测、跌倒检测）、识别（多分类，如活动识别、手势识别、行人识别）与估计（数值输出，如呼吸率估计、定位）^{ma2019wifi}。本文关注的室内动作识别属于识别类应用。Wi-Fi 感知在实际部署中面临共性挑战：鲁棒性与泛化（不同环境、设备、人体差异）、隐私与安全（无线信号可被窃听）、传感与通信共存（感知与数据传输共享信道资源）^{ma2019wifi}。

综上，基于 Wi-Fi CSI 的人类活动识别原理可概括为：利用 CSI 对多径信道幅度与

相位的精细刻画，建立人体行为与环境信道变化之间的映射；通过信号预处理、特征提取与分类或估计算法，从 CSI 数据中推断室内动作类别。该原理为本文第三、四章中面向 Wi-Fi CSI 的类增量学习与少样本类增量学习方法提供了数据基础与物理背景。在本文后续实验中，原始 CSI 经预处理后被组织为固定长度的时序特征序列，不同数据集依据采集设备与预处理方式形成不同输入维度。例如，XRF 样本主要表示为 270 维 CSI 时序特征，WiAR 样本则可整理为 90 通道 CSI 时序表示。后续方法设计重点不再放在信号级去噪，而放在基于时序表示的分类模型构建。

2.2 增量学习

类增量学习关注的是类别集合随时间不断扩展时模型应如何完成持续更新。与一次性获得全部类别数据的离线训练不同，该任务要求模型在后续阶段仅利用当前到达的数据学习新类别，同时继续保持对历史类别的识别能力。其困难不只在在于新旧知识之间存在竞争关系，还在于模型容量、样本分布和训练目标会随着增量过程不断变化。按照测试条件和增量对象的不同，持续学习通常可区分为类增量学习、任务增量学习和域增量学习等设定；其中，类增量学习在推理阶段不提供任务标识，需要模型直接在全部已见类别范围内完成判别，因此约束更强，也更适合刻画本文所关注的类别持续扩展场景^{zhou2024cil}。

除数据重放、动态网络与知识蒸馏外，还有基于数据正则化（如 GEM^{lopezpaz2017gem} 约束梯度方向）与参数正则化（如 EWC^{kirkpatrick2017ewc} 约束重要参数漂移）的方法；但在 CIL 场景下，这两类方法的效果多不如回放与动态网络^{zhou2024cil}。鉴于第三章方法主要由记忆回放、分类器扩展和蒸馏巩固三部分组成，本节重点介绍与上述设计直接相关的数据重放、动态网络和知识蒸馏方法。

2.2.1 数据重放

在类增量学习中，数据重放的基本思路是为模型保留一部分历史信息，使其在适应新类别时不至于完全脱离旧类别分布。最常见的做法是在每次增量训练时，将当前任务样本与旧类别中选取的代表样本共同用于参数更新。这样一来，模型在优化新类别判别边界的同时，仍会持续接触旧类别特征，从而减轻旧知识被新知识覆盖的现象。由于这一策略直接作用于训练数据层面，其实现方式相对直观，也因此成为类增量学习中使用最广泛的基础手段之一^{zhou2024cil}。

该思路与人类认知中的“复习”现象一致：在接触新知识时反复回顾旧知识有助于巩固记忆^{zhou2024cil}。

直接回放（Direct Replay）是最直观的形式。模型维护一个 exemplar 集合 $\mathcal{E}$ ，在每轮增量更新时将当前任务数据 $\mathcal{D}^b$ 与 exemplar 联合训练，其损失可写为

$$\mathcal{L} = \sum_{(\mathbf{x}, y) \in (\mathcal{D}^b \cup \mathcal{E})} \ell(f(\mathbf{x}), y), \quad (2-3)$$

式中： $\mathcal{D}^b$ ——第 b 个任务的新类训练数据； $\mathcal{E}$ ——旧类 exemplar 集合（与 $\mathcal{D}^b$ 联合用于经验损失 $\mathcal{L}$ ）。

式 (??) 给出了当前任务数据与 exemplar 联合训练时的优化目标。相较仅使用 $\mathcal{D}^b$ 的 Finetune，该形式使模型在学习新类时仍能访问旧类样本，从而减弱遗忘。

Exemplar 的选取与管理直接影响重放效果。Herding 策略迭代选取最接近类均值的样本，使选中的 exemplar 平均特征尽量贴近类中心；此外还有基于预测熵、决策边界距离、数据增强不确定性等策略。在内存约束下，常采用固定总容量 M 、每类分配 $\lfloor M/|\mathcal{V}_b| \rfloor$ 个样本的方式，避免随任务数线性增长^{zhou2024cil}。为降低存储成本，部分工作采用特征回放（存储特征向量而非原始图像）或低分辨率图像回放，但需额外适配以克服分布偏移。

生成式回放（Generative Replay）利用生成模型（如 GAN、VAE、扩散模型）合成旧类伪样本，从而无需存储原始 exemplar。该类方法依赖生成质量，在简单数据集上效果尚可，但在复杂大规模数据上常因生成失真而性能受限；且生成模型本身也会发生灾难性遗忘，需在分类器与生成器两端同时设计抗遗忘机制^{zhou2024cil}。

直接回放在 CIL 中应用广泛，但面临过拟合、新旧类数据不平衡以及隐私等问题。针对过拟合，可通过对 exemplar 施加 Lipschitz 约束或平衡采样加以缓解；在隐私或存储受限场景下，则需采用无 exemplar 或隐私友好的设计，亦有工作从模型扩展与压缩角度降低回放存储开销^{zhou2023memo}。本文第三章的类增量学习方法即采用数据重放策略，通过类均值最近邻迭代选择构建记忆库，缓解旧类数据不可及问题。

2.2.2 动态网络

与依靠有限样本回顾旧知识的思路不同，动态网络更强调通过扩展模型结构来为新类别分配额外表示能力。其核心出发点在于：当固定容量网络反复适配新任务时，新学习到的特征往往会挤占原有表征空间，从而引发遗忘；若能够在增量过程中为新任务引入新的参数模块，则旧知识可以在原有结构中相对稳定地保留下来，而新知识则由新增结构承担。这类方法并不试图完全依赖单一参数集合兼顾全部阶段，而是通过结构扩展在稳定性与可塑性之间取得平衡^{zhou2024cil}。

神经元扩展早期工作（如 DEN^{yoon2018den}）采用选择、扩展、复制与消除等流程：面对新任务时先选择性重训相关神经元，若损失仍高则自上而下扩展新神经元，并通过组稀疏正则剔除冗余。RCL、NAS 等将扩展过程形式化为强化学习或结构搜索问题。骨干扩展则进一步复制整条骨干网络。PNN^{rusu2016pnn} 为每个任务学习新骨干并冻结旧骨干，通过层间连接复用旧特征。DER^{yan2021der} 在每任务扩展新骨干，将新旧骨干特征拼接后接入更大的全连接层，输出可写为 $f(\mathbf{x}) = W_{\text{new}}^T [\phi_{\text{old}}(\mathbf{x}), \phi_{\text{new}}(\mathbf{x})]$ ，旧骨干冻结以保持旧类表征。该设计带来参数量线性增长，FOSTER 在扩展后引入知识蒸馏压缩阶段，将双骨干蒸馏回单骨干，在控制参数量的同时保留判别能力^{wang2022foster}。MEMO^{zhou2023memo} 将骨干解耦为共享浅层与任务专属深层，仅扩展深层块，在内存约束下实现高效扩展。

在 ViT 场景下，Prompt 扩展（如 L2P^{wang2022l2p}、DualPrompt^{wang2022dualprompt}、Dy-

Tox^{douillard2022dytox}) 通过为每任务扩展 task token 或 prompt, 以较轻量方式适配新类, 多依赖预训练骨干。本文第三章的方法采用“分类器扩展 + 知识蒸馏巩固”的思路, 与 FOSTER 的扩充—压缩范式在设计理念上相呼应。

2.2.3 知识蒸馏

知识蒸馏在类增量学习中的作用, 主要是利用上一阶段模型所保留的判别信息约束当前模型的更新方向。与仅依赖标签监督不同, 蒸馏方法会进一步要求新模型在旧类别相关输出、特征表示或样本关系上尽量接近旧模型, 从而在学习新类别时减少旧知识的大幅偏移。由于蒸馏不一定依赖大量历史原始数据, 因此在存储受限或回放样本较少的条件下具有较高实用性, 也是许多增量学习方法中常见的组成部分^{zhou2024cil, hinton2015distilling}。

将上一阶段模型 f^{b-1} 视为教师、当前更新模型 f 视为学生时, 可通过约束二者在旧类上的输出或特征一致性将旧知识迁移至新模型^{hinton2015distilling}。

Logit 蒸馏约束旧类输出概率一致。LwF^{li2017lwf} 在交叉熵损失外添加蒸馏正则项, 使新模型在旧类上的软标签与旧模型一致。iCaRL^{rebuffi2017icarl} 结合 exemplar 与蒸馏, 并采用最近类均值推理。BiC^{wu2019bic} 引入动态权衡系数 $\lambda = |\mathcal{V}_{b-1}|/|\mathcal{V}_b|$, 并附加偏差校正层以缓解新旧类 logit 偏移。Feature 蒸馏则约束嵌入或中间特征。UCIR^{hou2019ucir} 使用余弦相似度约束新旧嵌入一致; LwM^{dhar2019lwm} 约束注意力图; PODNet^{douillard2020podnet} 对池化后的空间特征做蒸馏。Relational 蒸馏关注样本间结构关系: R-DFCIL 对齐三元组角度关系; TPCIL、TOPIC 等通过图或神经网络建模类间关系并对齐。

蒸馏常配合温度软化 softmax 与 KL 散度使用。其难点在于稳定性—可塑性权衡: 蒸馏权重过大将抑制新类学习, 过小则难以抵抗遗忘。与动态网络相比, 蒸馏方法在内存受限时往往更优, 但在充足内存下动态网络的扩展表征能力更具优势^{zhou2024cil}。

图 ?? 给出了知识蒸馏在 CIL 中的三类形式示意。综上, 数据重放、动态网络与知识蒸馏可单独或组合使用, 为本文后续面向 Wi-Fi CSI 的类增量学习设计提供了方法基础。




图 2-2 CIL 中知识蒸馏的三种形式

2.2.4 基于类别表征的混淆抑制方法

除数据重放、动态网络和知识蒸馏外，近年来也有研究从类别表征能力和类别级混淆角度改进类增量学习。传统原型类方法通常使用单一类均值或少量原型表示类别分布，虽然结构简洁，但当同一类别在特征空间中呈现多峰或复杂流形结构时，单一原型难以完整刻画类别分布；同时，增量训练导致的特征漂移还可能使旧类和新类特征发生重叠，从而引发类别级混淆。针对上述问题，Chen 等提出 CREATE 方法^{chen2025create}，为每个类别构建轻量级自编码器，以学习类别特定的低维紧凑流形，并利用重构误差度量样本与类别流形之间的匹配程度。进一步地，该方法通过混淆感知的潜空间分离损失，使同类样本在对应子空间中更加紧凑，同时推远易混淆异类样本，从而缓解特征漂移和类别重叠带来的错误判别。该方法说明，类增量学习不仅需要关注旧知识保持和新类学习，还需要提升类别分布表达能力并抑制新旧类别之间的混淆。

2.3 少样本学习

少样本学习关注的是在监督信息有限的条件下如何获得可迁移的判别能力。与依赖大量标注样本拟合类别边界的常规监督学习不同，少样本学习更强调通过任务结构、相似度度量或先验知识提高模型对少量样本的利用效率^{tian2024fscilsurvey,zhaokailin2021fslreview}。在典型的 N -way K -shot 设定中，模型只能借助每类极少量支持样本完成对查询样本的分类，因此其性能很大程度上取决于表示空间是否具有足够的泛化性，以及模型是否能够从有限样本中提取稳定类别信息^{tian2024fscilsurvey,zhaokailin2021fslreview}。考虑到第四章方法需要在极少样本条件下完成新类建模，本节重点介绍与原型表示、相似度度量和样本扩展直接相关的少样本学习方法，为后续双分类器与图注意力建模提供背景。

2.3.1 数据增强

数据增强通过增加已有数据的多样性缓解样本稀缺，降低过拟合风险并提升泛化能力^{tian2024fscilsurvey}。按数据来源可分为三类：基于训练集变换、基于弱标签或无标签数据、基于相似数据集。第一类对支持集样本施加几何变换（旋转、裁剪、翻转）、颜色抖动等；第二类利用无标签或半监督数据扩展表示学习；第三类从语义相近的数据集迁移样本或特征。

除直接变换外，还可利用生成模型合成新样本或特征。VAE、GAN 等通过建模数据分布，在隐空间采样生成伪样本，或直接在特征空间生成合成特征，以扩充支持集并缓解过拟合^{tian2024fscilsurvey}。在 FSCIL 场景下，数据增强常与度量学习或原型学习配合，用于基础阶段增强或增量阶段的虚拟样本生成。

2.3.2 度量学习

度量学习方法在嵌入空间中通过样本与支持集之间的相似度或距离进行分类，无需大量数据即可优化度量以拉近同类样本、拉远异类样本^{tian2024fscilsurvey}。

孪生网络（Siamese Network）^{koch2015siamese}采用双分支结构，对一对输入样本分别提取特征并计算特征间距离，通过对比损失学习判别性嵌入。匹配网络（Matching Network）^{vinyals2016matching}利用注意力机制对支持集与查询样本进行动态匹配与聚合，为每个查询生成与类别相关的表示。原型网络（Prototypical Network）将每类表征为其支持集样本嵌入的均值，即类原型 $\mu_c = \frac{1}{|S_c|} \sum_{\mathbf{x} \in S_c} f_\theta(\mathbf{x})$ ，其中 c 为类别索引， S_c 为该类别的支持集样本集合， $f_\theta(\cdot)$ 为参数化嵌入映射（ θ 为网络参数）；推理时根据查询嵌入与各原型的欧氏距离或余弦相似度进行最近邻分类。图 ?? 给出了上述三种网络的结构对比。

度量学习的核心在于原型表示与相似度度量的设计。在 FSCIL 中，原型网络因结构简洁、易于扩展新类而被广泛采用；但其在增量场景下面临原型漂移、新旧类冲突等问题。本文第四章在原型表示基础上引入图注意力网络建模类间关系，并采用双分类器架构缓解类别级过拟合，其原型初始化与余弦分类的设计与度量学习及原型学习的思路一脉相承。

除度量学习外，FSL 还有模型类与优化类方法。模型类方法通过特定网络结构应对少样本：记忆增强网络（MANN）用外部记忆显式存储类别信息，利用长时记忆进行快速学习；Meta 网络学习跨任务的元级知识，通过快速参数化调整归纳偏置以实现泛化^{tian2024fscilsurvey}。优化类方法侧重训练策略：模型无关元学习（MAML）^{finn2017maml}在多个任务上训练初始参数，使新任务上能快速收敛；Reptile^{nichol2018reptile}将 MAML 的二步梯度简化为单步，降低计算开销。这些方法与度量学习互补，在 FSCIL 中常与原型、图结构等组合使用。




图 2-3 度量学习方法常见网络结构

2.4 少样本类增量学习

少样本类增量学习同时受到类别持续扩展与新类样本极少这两重约束^{tian2024fscilsurvey,tao2020topic}。模型不仅要在后续会话中识别此前未见的新类别，还要在旧类样本难以访问的条件下尽量维持已有类别的判别边界。相比第三章讨论的类增量学习，FSCIL 的困难进一步体现在：新类样本不足会削弱类别原型或决策边界的稳定性，而持续更新又会放大新旧类别之间的竞争关系。因此，该任务本质上要求模型同时处理表示学习不足、类别偏置和灾难性遗忘等多个问题^{tian2024fscilsurvey,tao2020topic}。在中文研究中，姚光乐等提出了基于特征分布学习的小样本类增量学习方法，通过利用已学习类别的特征分布信息来表示知识，并在增量阶段融合新类特征分布，从而缓解少样本条件下的新类过拟合与旧类遗忘问题^{yaoguang2023fscildist}。

现有 FSCIL 方法通常采用「先在基础类别上学习通用表征，再在增量阶段适配新类别」的总体训练思路。其原因在于，基础阶段拥有相对充足的数据，更适合用于构建稳定的特征提取器；而进入增量阶段后，模型需要在极少样本条件下快速完成新类接入，因此更新重点往往会从完整表征学习转向分类器调整、原型构建或关系建模。围绕这一基本流程，不同研究又在数据利用方式、网络结构设计和训练目标构造上进行了进一步扩展^{tian2024fscilsurvey}。为缓解少样本下的过拟合与遗忘，部分工作扩展监督策略：在增量会话中引入无标签样本，将半监督学习与 FSCIL 结合；或利用自监督预训练获得双骨干特征提取器，再通过高斯生成器与特征融合适应新类^{tian2024fscilsurvey}。本节从基于数据、基于结构与基于优化三个维度概述 FSCIL 主流方法，为本文第四章少样本增量学习方法的设计提供理论背景。

2.4.1 基于数据

基于数据的 FSCIL 方法通过重放或合成旧类样本，使模型在学习新类时仍能接触旧类信息。直接重放维护 episode 记忆 $\mathcal{M}$ ，在增量更新时将当前任务数据 $D^{(t)}$ 与 $\mathcal{M}$ 联合训练，损失形式与式 (??) 类似。但直接存储 exemplar 在少样本场景下面临存储、样本选择与隐私约束；且新旧类样本量失衡时，知识蒸馏等依赖 exemplar 的方法易在性能权衡上偏于旧类^{tian2024fscilsurvey}。

生成式重放利用生成模型合成旧类伪样本，避免存储原始数据。数据无重放 (data-free replay) 方案通过熵正则鼓励生成器产生接近决策边界的“不确定”样本；FSILGAN 等针对少样本场景设计 GAN，将类别特定的合成视觉特征与语义向量对齐，并利用抗模式塌缩正则保证合成特征的多样性与可区分性。生成式重放的挑战在于少样本下难以逼近真实数据分布，且生成质量直接影响抗遗忘效果^{tian2024fscilsurvey}。

除真实或合成重放外，部分工作通过构建伪增量场景进行元学习。例如从基础类中采样模拟增量任务序列，在元训练阶段学习适应新知识与保留旧知识的元目标；LIMIT^{zhou2022limit} 等在基础集上构造“假”FSCIL 任务，通过不同假任务的元学习获得更具泛化性的特征，为真实增量阶段做准备^{tian2024fscilsurvey}。

2.4.2 基于结构

基于结构的方法通过动态调整网络拓扑或模块，使模型随增量任务扩展表示能力。Tao 等提出的 TOPIC^{tao2020topic} 利用神经气 (Neural Gas, NG) 网络学习特征空间中各类形成的拓扑结构；通过保持 NG 拓扑稳定性抵抗遗忘，同时随新样本动态扩展以改善少样本新类表示。Zhang 等提出的 CEC^{zhang2021cec} 将训练解耦为嵌入学习与分类器学习：先在基础数据上训练骨干获得强特征提取能力，再在分类器层引入图注意力模型；随增量任务到达，图模型的节点与边权动态增长，使分类器适应全部类别。Zou 等发现大间隔分类虽有利于基础类，但易导致学习新类时性能下降，称为类别级过拟合；CLOM^{zou2022clom} 引入基于边界的额外约束以缓解该问题，并采用双分类器架构分离基础类与新类决策。

Pan 等提出的 DyCR^{pan2025dyer} (Dynamic Clustering and Recovering Network) 属于动态恢复型 FSCIL 方法。针对多数方法在增量阶段冻结骨干网络、导致新类特征适配不足的问题，DyCR 在增量阶段仍保持子网络可训练，并引入特征正交分解将嵌入划分为上下文分量与类别分量：前者以上下文图形式在会话间保留，并与类原型结合以恢复旧类样本嵌入，从而在较小存储开销下缓解灾难性遗忘；后者通过原型引导的距离缩放与深度度量学习拉近同类、推远易混异类，以优化嵌入空间的类内紧凑与类间分离。该动态网络一分解一恢复范式与 CSI 时序任务中「少样本增量 + 旧类不可回放」的设置具有对照意义，故第四章将其作为近年先进基线之一纳入对比。

上述图注意力与双分类器思路与本文第四章少样本增量学习方法一脉相承：该方法在原型基础上引入增强图注意力建模类间与时序关系，并采用双分类器缓解类别级过拟合。

2.4.3 基于优化

基于优化的方法从表示学习、知识蒸馏与目标函数形态等方面调整训练策略。表示学习方面，前向兼容训练 (FACT)^{zhou2022fact} 在特征空间预分配虚拟原型，为未来新类预留空间，通过实例混合生成虚拟样本使模型具有前向兼容性；LIMIT^{zhou2022limit} 等则通过元校准模块生成实例特定的嵌入以提升泛化。知识蒸馏在 FSCIL 中可用于转移旧知识，但少样本场景下新旧类失衡使其效果受限；语义感知蒸馏通过引入词嵌入等辅助信息、图关系蒸馏（如 ERDIL）通过维护类间关系图进行知识抽取与表示，一定程度上缓解了上述问题^{tian2024fscilsurvey}。

从函数优化角度，F2M^{shi2021f2m} 等工作发现基础训练所得的平坦局部极小值比尖锐极小值具有更好的泛化能力；在平坦区域内对新任务进行微调可大幅减轻灾难性遗忘。稳定性—可塑性权衡贯穿 FSCIL：过度稳定将抑制新类学习，过度可塑则加速遗忘；ERM 在样本稀缺时不可靠，需结合元学习、正则化或结构设计加以应对。与视觉图像不同，Wi-Fi CSI 数据具有显著的时序性和跨子载波结构，因此现有 FSCIL 方法在迁移到 Wi-Fi 感知任务时需考虑时序表征与模态适配问题。综上，基于数据、结构与优化的方法可单独或组合使用，为面向 Wi-Fi CSI 的少样本类增量学习（如本文第四章）提供方法基础。

2.5 本章小结

综上，本章从 Wi-Fi CSI 感知原理、类增量学习、少样本学习和少样本类增量学习四个方面梳理了本文所需的理论基础。其中，CSI 时序表征构成了第三、四章共同的数据基础；数据重放、动态扩展和知识蒸馏构成了第三章方法设计的核心依据；原型表示、相似度建模和类间关系传播则为第四章方法设计提供了直接支撑。此外，类别表征与混淆抑制方法为第三章引入 CREATE^{chen2025create} 等近年类增量学习对比方法提供了理论参照。基于此，下一章将首先讨论样本相对充足条件下的类增量学习方法。

3 面向 Wi-Fi 信号动作识别的类增量学习方法研究

3.1 问题描述

第二章已经从数据重放、动态网络结构与知识蒸馏等方面梳理了类增量学习的主要技术基础。基于上述理论背景，本章进一步面向 Wi-Fi CSI 室内动作识别中新增类别样本相对充足的持续更新场景，研究模型如何在类别集合逐步扩展时兼顾新类学习与旧类保持。与第四章讨论的少样本类增量学习不同，本章假设每个增量阶段能够获得一定规模的新类别训练样本，并允许在有限存储预算下保留少量旧类代表样本，因此研究重点在于如何在新旧类分布不平衡、旧类数据不可完整访问和模型结构稳定之间取得平衡。围绕该问题，本章构建回放—扩展—巩固框架：通过记忆库重放保留旧类代表信息，通过冻结骨干与分类器扩展完成新类接入，并通过教师—学生蒸馏实现跨阶段知识整合；并针对增量阶段新旧类样本不平衡与分类边界偏移，配合平衡微调、分类器重训练与双边知识蒸馏，将扩展后的新旧类知识统一巩固到单一模型中，以缓解灾难性遗忘。随后在 XRF 与 WiAR 数据集上开展实验，并在 XRF 对比实验中引入 CREATE^{chen2025create} 等近年类增量学习方法，以验证所提方法在不同 Wi-Fi CSI 数据条件下的有效性。下文在此基础上给出 Wi-Fi CSI 动作识别任务下的类增量学习形式化定义、研究思路与技术路线。

3.1.1 任务定义

本文第三章讨论的是面向 Wi-Fi CSI 室内动作识别的类增量学习问题。与固定类别集训练不同，该任务中的类别集合会随学习过程逐步扩展：模型在完成已有类别训练后，还需要在后续阶段继续接收新的动作类别，并在不重新访问全部历史训练数据的条件下完成更新。由于测试阶段需要直接在当前全部已见类别上进行统一判别，因此该任务既要求模型具备接纳新类别的能力，也要求其尽量维持旧类别识别性能。

为便于描述，设增量过程包含按顺序到来的多个训练阶段，第 b 个阶段的训练集记为 $\mathcal{D}^b$ ，其标签集合记为 y_b 。各阶段的标签空间两两不重叠，即不同阶段对应的是此前未出现过的新类别。随着训练推进，模型在第 b 个阶段结束后需要面向累计类别集合 $\mathcal{V}_b = y_1 \cup \dots \cup y_b$ 进行预测。对于基于回放的方法，训练时除当前阶段数据外，还可访问由旧阶段代表样本组成的记忆集合；而对于不依赖回放的设定，则模型只能利用当前阶段数据完成参数更新。无论采用何种训练机制，任务目标都在于：在持续吸收新类别知识的同时，尽可能减缓旧类别性能下降^{zhou2024cil}。




图 3-1 持续学习常见设定示意

沿用 CIL 领域常用的符号体系^{zhou2024cil}，下面进一步给出样本级表示与期望风险形式。设存在一个按顺序到来的任务序列 $\mathcal{D}^1, \mathcal{D}^2, \dots, \mathcal{D}^B$ ，其中第 b 个任务的训练集为 $\mathcal{D}^b = \{(\mathbf{x}_i^b, y_i^b)\}_{i=1}^{n_b}$ 。其中 $\mathbf{x}_i^b \in \mathbb{R}^D$ 表示一个 Wi-Fi CSI 样本， D 为样本经预处理后的特征维度；不同数据集的 D 可不同，例如 XRF 主实验对应 270 维 CSI 特征，WiAR 实验对应 90×512 的时序表示。 $y_i^b \in \mathcal{Y}_b$ 为该样本对应的动作类别标签， $\mathcal{Y}_b$ 为第 b 个任务的标签空间。各任务标签空间互不相交，即 $\mathcal{Y}_b \cap \mathcal{Y}_{b'} = \emptyset$ 对任意 $b \neq b'$ 成立。训练第 b 个任务时，模型只能访问当前任务的训练数据 $\mathcal{D}^b$ ，以及通过记忆回放保留的旧任务 Exemplar 子集 $\mathcal{E}$ （若采用基于回放的方法）。类增量学习的最终目标是在每个任务训练结束后，得到一个能够对全体已见类别 $\mathcal{V}_b = \mathcal{Y}_1 \cup \dots \cup \mathcal{Y}_b$ 进行正确分类的模型 $f(\mathbf{x}) : \mathcal{X} \rightarrow \mathcal{V}_b$ 。形式化地，CIL 旨在最小化全体已见任务上的期望风险^{zhou2024cil}：

$$f^* = \arg \min_{f \in \mathcal{H}} \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}^1 \cup \dots \cup \mathcal{D}^b} \mathbb{I}(y \neq f(\mathbf{x})) \quad (3-1)$$

式中： f^* ——在假设空间上使误分类期望最小的最优映射； $\mathcal{H}$ ——假设空间（可选函数族）。

式 (??) 将类增量目标表述为在全体已见任务数据上最小化误分类指示的期望，是后续各增量步骤中优化目标的抽象形式，要求模型在吸收新类别知识的同时保留旧类别知识。

若直接用新类别数据对原模型进行微调（即 Finetune 基线），模型往往会发生灾难性遗忘：对新类别的拟合会覆盖旧类别的表示，导致对旧类别的识别能力急剧下降。因此，CIL 的核心挑战在于如何在学习新知识的同时保留旧知识，这对应于神经网络中的稳定性—可塑性困境（stability-plasticity dilemma）^{grossberg1982studies, zhou2024cil}。

在本文实验中，以 XRF 数据集为主场景模拟上述 CIL 设置；另在 WiAR 数据集上构造 WiAR-16 类增量设置（详见 3.3.1 节），用于在较小类别规模与不同 CSI 数据分布

下检验所提框架的适用性。XRF 数据集包含 55 类室内动作，对应 Wi-Fi CSI 信号经预处理后的 270 维特征。按项目配置，将数据划分为 5 个增量阶段（如图 ?? 所示）：初始任务 $\mathcal{D}^0$ 包含前 15 类，后续 4 个任务 $\mathcal{D}^1, \dots, \mathcal{D}^4$ 每个新增 10 类，即类别数依次为 15、25、35、45、55。训练集与测试集按 7:3 比例划分，每个增量阶段训练时仅能使用当前任务数据及记忆库中保存的旧类代表样本。

因此，该设置能够同时考察模型对新增动作类别的接纳能力，以及在有限旧类样本条件下对历史动作类别的保持能力。

同时，逐阶段扩展的类别序列也为后续准确率、ACCN 与平均准确率等指标分析提供了统一评估基础。




图 3-2 XRF 数据集在类增量学习场景下的任务划分

3.1.2 研究思路

在上述 XRF 增量设置下，若直接采用 Finetune（即仅用新类数据微调全部参数），模型在 Session 1 后旧类准确率即从约 90% 骤降至不足 40%（具体数据见 3.4 节），说明仅依靠当前任务数据无法维持旧类判别边界。这一现象促使本文在方法设计上做出以下选择。

第一，不直接更新全部参数，而是冻结骨干网络、仅扩展分类器。骨干在基础阶段已经学到了对 270 维 CSI 特征的通用表示，若在增量阶段继续更新骨干，新类样本会覆盖旧类表征。冻结骨干后，新类的判别由新增的分类器输出头承担，旧类的特征映射得以保留。

第二，仅扩展分类器虽能降低对旧类表征的破坏，但分类器扩展后的知识仍需整合到统一的表示空间。若直接沿用扩展后的参数进入下一阶段，消融实验显示模型准确率会骤降至接近随机猜测水平（见 3.4.3 节）。为此，本文在每轮增量结束后引入教师—学生蒸馏：以扩展后的网络为教师，以独立初始化的同结构网络为学生，通过软标签监督与特征对齐将教师积累的新旧类知识迁移至学生，再以学生替代教师作为下一阶段的基模型。

第三，增量学习中旧类数据不再可得，但推理时需在全体已见类别上统一分类。为缓解数据不可及带来的遗忘，本文在内存中为每个旧类保留少量代表样本（Exemplar），在每轮增量训练中与新类数据联合使用。

基于上述三点，本章方法形成“回放—扩展—巩固”的整体流程，具体设计将在 3.2 节展开。

本章创新点概括如下：

（1）面向 Wi-Fi CSI 类增量动作识别，将记忆重放、冻结骨干下的分类器扩展与教师—学生式知识巩固组织为统一的增量训练流程，使新类接入与旧类保持在同一优化闭环中协同进行，以应对类别持续扩展带来的分布漂移与灾难性遗忘。

（2）在增量阶段显式冻结 CSI 特征提取骨干，仅通过扩展分类器参数吸收新类判别信息，降低新类梯度对旧类已学表征空间的直接覆盖，从而在 Wi-Fi CSI 时序特征上减弱「新类拟合挤压旧类边界」的典型退化模式。

（3）在分类器扩展之后引入双边知识蒸馏与巩固步骤，将扩展阶段分散于教师网络中的新旧类判别能力迁移回单一学生主干，使下一增量阶段仍可在结构简洁的前提下继承跨阶段知识，缓解多会话训练中的性能坍塌风险。

3.2 回放—扩展—巩固框架设计

新任务到来时，若能在模型中预留一定“空间”去吸收新知识，再在后续步骤中通过蒸馏将新旧知识巩固到单一主干中，便能在适应新类别的同时保持结构简洁。沿用 CIL 领域常用写法^{zhou2024cil}，将模型分解为嵌入函数与线性分类器的组合：

$$f(\mathbf{x}) = \mathbf{W}^\top \phi(\mathbf{x}) \quad (3-2)$$

式中： $\phi(\cdot)$ ——特征提取映射； $\mathbf{W}$ ——线性分类器权重矩阵。

式(??)将 CSI 样本映射为嵌入并由线性分类器给出类别打分，把特征提取与类别判别显式分离，为后续在冻结 ϕ 的前提下仅扩展 $\mathbf{W}$ 提供形式化基础。

本文的增量策略受梯度提升（Gradient Boosting）思想启发^{friedman2001gbm,wang2022foster}。梯度提升的核心是在函数空间中进行梯度下降：给定当前模型 F_m 与损失函数 L ，第 $m+1$ 步沿负梯度方向寻找最优更新，即

$$F_{m+1}(\mathbf{x}) = F_m(\mathbf{x}) - \rho_m \nabla_F L(y, F_m(\mathbf{x})) \quad (3-3)$$

式中： $F_m(\mathbf{x})$ ——第 m 步加性模型输出； ρ_m ——第 $m+1$ 步步长系数。

式(??)给出梯度提升在函数空间沿负梯度方向更新近似的一般形式。以均方误差损失 $L(y, F) = \frac{1}{2}(y - F)^2$ 为例，负梯度恰好等于残差：

$$-\frac{\partial L(y, F)}{\partial F} = y - F_m(\mathbf{x}) \quad (3-4)$$

式中： $F_m(\mathbf{x})$ ——第 m 步模型输出； y ——与模型输出同型的回归或分类目标。

式 (??) 表明，新增的可训练模块 h_{m+1} 拟合的是当前模型输出与目标之间的差： $F_{m+1}(\mathbf{x}) = F_m(\mathbf{x}) + h_{m+1}(\mathbf{x})$ 。将这一思想类比到类增量学习中，旧模型 F_m 仅能识别已见类别，面对新类别时存在“残差”——即新类目标分布与当前输出之间的差距。通过新增可训练模块拟合该残差，模型可在不破坏旧类表征的前提下获得对新类的判别能力。

本文将增量过程分为两步：先通过可训练模块扩充模型对新老类别的判别能力，再借助知识蒸馏将扩充后的知识迁移回单一主干，从而在保持结构简洁的前提下完成知识的整合。整体流程如图 ?? 所示。




图 3-3 面向 Wi-Fi CSI 动作识别的增量训练流程

3.2.1 基于类均值选样的记忆回放

增量学习中，旧类别数据往往不再可得，而推理时却需要模型能区分所有已见类别。一个自然的做法是，在学习新任务时重放一部分旧类样本，让模型在拟合新类的同时仍能接触到旧类数据，以维持对旧边界的记忆^{zhou2024cil, rebuffi2017icarl}。因此，在内存受限的约束下，如何选取并保留最具代表性的旧类样本成为关键问题。

本文采用类均值最近邻迭代选择^{rebuffi2017icarl}来构建记忆库。其思路是，对每个类别，从训练集中迭代选取 m 个代表样本，使得所选样本在特征空间中的均值尽可能逼近该类的整体均值，从而用少量样本近似类的分布。形式化地，设第 c 类共有 n_c 个训练样本，经当前特征提取器 ϕ 得到特征集合 $\{\mathbf{v}_1^c, \dots, \mathbf{v}_{n_c}^c\}$ ，第 c 类的类原型（类中心）定义为

$$\mu_c = \frac{1}{n_c} \sum_{i=1}^{n_c} \phi(\mathbf{x}_i^c) \quad (3-5)$$

式中： μ_c ——第 c 类类均值原型； n_c ——该类训练样本个数。

式 (??) 定义第 c 类的类原型（类中心）。在第 k 步（ $k = 1, \dots, m$ ）从剩余样本中选择使当前已选样本均值与 μ_c 最接近的样本：

$$\mathbf{i}_k = \arg \min_i \left\| \mu_c - \frac{1}{k} \left(\sum_{j=1}^{k-1} \mathbf{v}_{\mathbf{i}_j}^c + \mathbf{v}_i^c \right) \right\|_2 \quad (3-6)$$

式中： $\mathbf{i}_k$ ——Herding 第 k 轮选定的样本索引； μ_c ——第 c 类类均值（见式 (??)）。

式 (??) 给出类均值最近邻迭代选取规则。选中的样本从候选集中移除，直至选满 m 个。这样得到的 Exemplar 集合 $\mathcal{E}$ 将在后续每个增量阶段与新任务数据 $\mathcal{D}^t$ 合并，作为联合训练集 $\hat{\mathcal{D}}^t = \mathcal{D}^t \cup \mathcal{E}$ 。在联合数据上的回放损失可写为

$$\mathcal{L}_{\text{replay}} = \sum_{(\mathbf{x}, y) \in \hat{\mathcal{D}}^t} \ell(f(\mathbf{x}), y) \quad (3-7)$$

式中： $\mathcal{L}_{\text{replay}}$ ——联合训练集上的分类经验损失； $\hat{\mathcal{D}}^t$ ——当前任务数据 $\mathcal{D}^t$ 与 exemplar 集合 $\mathcal{E}$ 的并集。

式 (??) 在联合数据上累计新类与旧类 exemplar 的分类损失，用于在增量训练中同时约束新类拟合与旧类回放。实验中，对 XRF 数据集每类保留 $m = 75$ 个样本，特征采用 L2 归一化后参与上述计算。

3.2.2 冻结骨干下的分类器扩展

有了记忆库支撑，下一步是如何让模型有效拟合新增类别，又不致覆盖已学表征。为此，每个增量步骤 t 到来时，首先将上一阶段的特征提取器 Φ_{t-1} 全部冻结，只扩展分类器——即在原有 $|\mathcal{V}_{t-1}|$ 类输出基础上，增加 $|\mathcal{V}_t \setminus \mathcal{V}_{t-1}|$ 个新类对应的输出头，形成 $\mathbf{W}_t \in \mathbb{R}^{d \times |\mathcal{V}_t|}$ 。形式化地，模型输出为

$$f_t(\mathbf{x}) = \mathbf{W}_t^\top \Phi_{t-1}(\mathbf{x}), \quad \mathbf{W}_t \in \mathbb{R}^{d \times |\mathcal{V}_t|} \quad (3-8)$$

式中： $\mathbf{W}_t$ ——第 t 步扩展后的分类器权重； $\Phi_{t-1}(\cdot)$ ——冻结的上一阶段特征提取器。

式 (??) 给出冻结骨干 Φ_{t-1} 时仅通过增广 $\mathbf{W}_t$ 获得新类 logits 的线性形式： Φ_{t-1} 冻结， $\mathbf{W}_t$ 在原有 $|\mathcal{V}_{t-1}|$ 列基础上扩展 $|\mathcal{V}_t \setminus \mathcal{V}_{t-1}|$ 列。旧类 logits 由旧列保留，新类由新增列承担，从而在单主干架构下拟合新增类别的“残差”。

对于 Wi-Fi CSI 时序特征而言，骨干网络主要承担对动作扰动模式的通用表征提取，若在每轮增量中频繁更新，容易使旧类已形成的时序判别结构发生漂移。因此，本节仅扩展分类器参数，将新类别适配限制在判别层完成，以在保持旧类表征稳定的同时为新类别提供独立输出空间。

训练数据为 $\hat{\mathcal{D}}^t = \mathcal{D}^t \cup \mathcal{E}$ 。由于记忆库每类仅保留有限样本，而新类样本通常远多于旧类 Exemplar 之和，数据分布会出现明显的新类偏置，进而导致分类器权重和 logits

向新类倾斜。为缓解这一问题，在按交叉熵

$$\mathcal{L}_{\text{CE}} = - \sum_{(\mathbf{x}, y) \in \hat{\mathcal{D}}^t} y \log \text{softmax}(\mathbf{W}_t^\top \Phi_{t-1}(\mathbf{x})) \quad (3-9)$$

式中： $\mathcal{L}_{\text{CE}}$ ——扩展分类器的交叉熵损失； $\hat{\mathcal{D}}^t$ ——新任务与 **exemplar** 的联合训练集。

式 (??) 在联合数据上定义扩展阶段的标准多类交叉熵目标，用于扩展后分类器的初始对齐。完成该初始训练后，随后依次进行平衡微调与分类器重训练。

类别不平衡是类增量学习中的固有问题。在增量阶段 t ，新类别各有数百个训练样本，而旧类别每类仅保留 m 个 **Exemplar**（本文取 $m = 75$ ），导致联合训练集中各类样本数差异悬殊。这种不平衡会使标准交叉熵损失偏向样本较多的新类，分类器权重向新类倾斜，旧类的判别边界被压缩。为量化这种不平衡并设计针对性的损失加权策略，本文引入有效样本数（Effective Number of Samples）的概念^{cui2019classbalanced}。

设第 c 类的训练样本数为 n_c ，有效样本数定义为

$$E_{n_c} = \frac{1 - \beta^{n_c}}{1 - \beta} \quad (3-10)$$

式中： E_{n_c} ——样本数为 n_c 时的有效样本数； β —— $(0, 1)$ 上控制边际递减速度的超参数。

式 (??) 将各类别样本量映射为边际递减的有效计数，用于构造稀有类的更大损失权重：当 $\beta \rightarrow 0$ 时 $E_{n_c} \rightarrow 1$ （近似不加权）；当 $\beta \rightarrow 1$ 时 $E_{n_c} \rightarrow n_c$ 。对于样本较少的旧类（ $n_c = m$ ），有效样本数较小，对应较大的损失权重；对于样本充足的新类，有效样本数趋于饱和，权重相对降低。基于此，各类别的损失权重设为有效样本数的倒数： $w_c = 1/E_{n_c}$ ，归一化后得到平衡微调阶段的加权交叉熵损失

$$\mathcal{L}_{\text{BFT}} = - \sum_{(\mathbf{x}, y) \in \hat{\mathcal{D}}^t} \frac{w_y}{\sum_c w_c} \log \text{softmax}(\mathbf{W}_t^\top \Phi_{t-1}(\mathbf{x}))_y \quad (3-11)$$

式中： $\mathcal{L}_{\text{BFT}}$ ——平衡微调损失； w_y ——真实类别 y 的类别权重（ $w_y = 1/E_{n_y}$ ）。

式 (??) 在交叉熵上引入与有效样本数相关的类别权重。平衡微调采用较小的学习率和 **batch size**（实验中分别为 0.01 和 16），在加权损失的引导下用若干轮微调分类器，使新旧类在梯度层面获得更均衡的更新。微调后再进行分类器重训练：使用标准交叉熵在 $\hat{\mathcal{D}}^t$ 上训练若干轮以进一步巩固判别能力。上述过程均保持骨干冻结，仅更新 $\mathbf{W}_t$ 。

3.2.3 基于双边蒸馏的知识巩固

分类器扩展后，模型已具备对新旧类别的判别能力，但该知识分散在扩展后的教师网络中，需要整合到统一的表示空间以供后续增量阶段使用。为此，在每轮增量结束后引入知识巩固步骤：以扩展后的网络为教师，以独立初始化的同结构单主干网络为学生，通过蒸馏将教师知识迁移至学生，再用学生替代教师作为下一阶段的基模型。教

师与学生采用完全相同的骨干架构与分类器维度，参数量均约 20.76M——该阶段的核心目的并非缩减模型规模，而是借助蒸馏的软标签监督与特征对齐实现跨阶段的知识整合与巩固。消融实验表明，移除该步骤后 Session 4 准确率由 73.57% 骤降至 1.82%，几乎完全丧失判别能力，足见其必要性。

教师网络 $F_t^{(T)}(\mathbf{x}) = \mathbf{W}_t^\top \Phi_{t-1}(\mathbf{x})$ 的参数在蒸馏阶段全部冻结；学生 $F_t^{(S)}$ 与教师采用相同骨干（UNet 或 ResNet）和类别数，但参数独立初始化。学生通过最小化以下目标进行训练。

$$\mathcal{L} = \mathcal{L}_{\text{CE}} + \lambda_{\text{KD}} \cdot \mathcal{L}_{\text{KD}} \quad (3-12)$$

式中： $\mathcal{L}$ ——学生网络总损失； $\mathcal{L}_{\text{KD}}$ ——师生 logits 蒸馏项； λ_{KD} ——蒸馏项权重系数。

式 (??) 将硬标签监督与蒸馏项组合为学生网络在 $\hat{\mathcal{D}}^t$ 上的总优化目标。训练数据仍为 $\hat{\mathcal{D}}^t$ 。

蒸馏损失采用带温度的软化 softmax^{hinton2015distilling}，以传递教师除硬标签外的类间相对置信关系。设温度 $T = 2$ ，教师与学生 logits 分别为 $\mathbf{z}^T$ 、 $\mathbf{z}^S$ ，则

$$\mathcal{L}_{\text{KD}} = T^2 \cdot \text{KL} \left(\text{softmax} \left(\frac{\mathbf{z}^S}{T} \right) \parallel \text{softmax} \left(\frac{\mathbf{z}^T}{T} \right) \right) \quad (3-13)$$

式中： T ——蒸馏温度； $\mathbf{z}^S$ 、 $\mathbf{z}^T$ ——学生与教师的 logits。

式 (??) 给出带温度缩放的 KL 蒸馏项： $T > 1$ 使概率分布更平滑，类间相对顺序得以保留；系数 T^2 用于平衡温度对梯度尺度的影响。若骨干支持特征输出，还可采用双边知识蒸馏（Bilateral KD, BKD）：除 logit 级 KL 蒸馏外，在特征空间对学生施加对齐损失，使表示更贴近教师。设 ϕ^T 、 ϕ^S 分别为教师与学生的特征表示， λ_{feat} 为特征蒸馏权重（取 0.5），则

$$\mathcal{L}_{\text{BKD}} = \mathcal{L}_{\text{KD}} + \lambda_{\text{feat}} \cdot \|\phi^S(\mathbf{x}) - \phi^T(\mathbf{x})\|_2^2 \quad (3-14)$$

式中： $\mathcal{L}_{\text{BKD}}$ ——含特征对齐的双边蒸馏总损失； λ_{feat} ——特征对齐项权重。

式 (??) 在 logit 蒸馏之外增加特征对齐项。实验中在 UNet、ResNet 上均可使用该扩展。

此外，与 3.2.2 节中平衡微调的思路一致，蒸馏损失同样面临类别不平衡的影响：在联合训练集 $\hat{\mathcal{D}}^t$ 中，新类样本占比远高于旧类 Exemplar，标准蒸馏损失对各样本一视同仁，可能导致教师在旧类上积累的知识未被学生充分吸收。为此，可对蒸馏损失引入与有效样本数成反比的权重，得到加权蒸馏损失

$$\mathcal{L}_{\text{wBKD}} = \frac{1}{|\hat{\mathcal{D}}^t|} \sum_{(\mathbf{x}, y) \in \hat{\mathcal{D}}^t} \frac{w_y}{\bar{w}} \cdot \mathcal{L}_{\text{BKD}}(\mathbf{x}) \quad (3-15)$$

式中： $\mathcal{L}_{\text{wBKD}}$ ——按类别加权后的双边蒸馏损失； $\bar{w}$ ——类别权重 w_y 的均值（尺度归一

化)。

式(??)使旧类样本在蒸馏中获得更大权重,在增量后期旧类数量增多但每类 exemplar 固定时尤为重要。

从认知科学的角度看,上述教师—学生双结构与互补学习系统(Complementary Learning Systems, CLS)理论^{mcclelland1995cls, pham2021dualnet}存在内在联系。CLS 理论认为,哺乳动物大脑通过两个互补系统协同学习:海马体负责快速编码新经验,新皮层负责缓慢整合与巩固长期知识,两者通过“经验重放”(如睡眠期间的记忆重放)实现知识迁移。在本文框架中,分类器扩展阶段类似于海马体的快速学习——模型通过新增参数迅速适应新类别;知识蒸馏阶段则对应新皮层的缓慢整合——教师将新旧知识通过软标签传递给学生,实现跨阶段的知识巩固。记忆库中的 Exemplar 重放则直接对应 CLS 中的经验重放机制,确保旧类记忆在整合过程中不被覆盖。这一类比为本文的方法设计提供了理论基础。

蒸馏阶段训练 150 轮,学习率取主训练的 0.1 倍。结束后将学生参数写入主网络,作为下一增量任务的起点,教师网络则备份以供后续蒸馏使用。

3.3 实验设置

为验证前述方法在 Wi-Fi CSI 动作识别任务上的效果,本节说明实验所采用的数据集、划分方式、训练配置及对比设置。

3.3.1 数据集与划分

数据集选取。实验选用 XRF 与 WiAR 数据集。在选取数据集时,对比了 Widar3.0^{zhang2019widar3}、WiAR^{guo2019wiar}、ARIL^{wang2019jointharwifi}、MM-Fi^{yang2023mmfi}、UT-HAR^{yousefi2017wifiharsurvey} 等现有开源 Wi-Fi 室内动作识别数据集。如表 ?? 所示, XRF 在类别数量(55 类)和样本规模(约 33000 条)上均明显优于多数数据集,且涵盖人一物交互、人—人交互、健身、身体运动与人—机交互等五大类室内活动。选择 XRF 的主要原因有两点:其一,55 个动作类别能够支持多阶段类别扩展设置;其二,样本总量约 33000 条,能够保证基础阶段训练与后续增量实验的稳定性。相比类别数较少的数据集, XRF 更适合构造 15 类基础任务加 4 个增量任务的 CIL 场景。此外,每类动作由 30 名志愿者采集、每人每类贡献 20 条数据,有助于减弱模型对单一主体动作模式的依赖。经预处理后,每条样本对应 270 维 CSI 特征向量,可直接输入骨干网络。WiAR 数据集用于构造较小类别规模下的类增量实验,与 XRF 形成互补。

数据集划分。按 3.1 节设定,将 XRF 划分为 5 个类别互不重叠的增量阶段:初始任务 $\mathcal{D}^0$ 含前 15 类,后续 4 个任务 $\mathcal{D}^1$ 至 $\mathcal{D}^4$ 各新增 10 类,类别数依次为 15、25、35、45、55。训练集与测试集按 7:3 划分,即每人每类 14 条入训练集、6 条入测试集。每个增量阶段训练时,模型仅可访问当前任务数据 $\mathcal{D}^t$ 及记忆库 $\mathcal{E}$ 。记忆库采用 3.2.1 节的类均值最近邻迭代选择构建,每类保留 $m = 75$ 个 Exemplar;该数值在保证记忆效果与控制内存占用之间做了折中,经预实验验证后采用。

对于 WiAR 数据集, 本文构造 WiAR-16 类增量实验设置。该设置包含 16 个动作类别, 初始阶段使用 6 个基础类别进行训练, 随后设置 5 个增量阶段, 每个阶段新增 2 个此前未见类别, 累计类别数依次为 6、8、10、12、14 和 16。与 XRF 实验一致, 每个阶段训练结束后均在当前全部已见类别上进行统一测试, 不提供任务标识。该划分方式能够在较小类别规模下模拟类别持续扩展过程, 并与第四章 WiAR 少样本类增量设置在类别集合和增量粒度上保持一致, 便于分析常规类增量学习与少样本类增量学习在样本条件和训练约束上的差异。

表 3-1 现有开源 Wi-Fi 室内动作识别数据集对比

数据集	类别数	主体数	样本数	动作类型
Widar3.0	16	16	17000	手势识别
WiAR	16	10	4800	身体运动、人机交互
ARIL	6	1	1394	人机交互
MM-Fi	27	40	320.76k 帧	日常活动、康复运动
UT-HAR	6	6	720	身体运动
XRF	55	30	33000	人物交互、人人交互、健身、 身体运动、人机交互

3.3.2 实验环境与硬件

实验在配备 NVIDIA GPU (CUDA 11.x) 的服务器上进行, 使用 Python 3.x 与 PyTorch 构建并训练模型。所有对比方法与本文方法均在同一环境下运行, 以确保结果可比。为减小随机性影响, 主对比实验与关键消融实验均在固定随机种子下重复多次, 结果报告其平均值。所有方法均采用相同的数据划分、随机种子与运行配置, 以减少非算法因素造成的性能波动。

3.3.3 训练配置

优化器与学习率调度。采用 SGD 优化器, momentum 0.9、Nesterov 加速, 权重衰减 2×10^{-4} 。学习率通过 MultiStepLR 调度: 在指定轮次后按 0.1 倍衰减, 以在训练后期实现更细致的收敛。

初始训练。基础 15 类阶段训练 250 轮, 初始学习率 0.1, 在第 80、150、200 轮后衰减。该阶段使模型在完整数据上充分收敛, 为后续增量学习奠定特征表示基础。

分类器扩展。每个增量任务中, 骨干冻结、仅训练分类器的阶段运行 150 轮, 学习率 0.1, milestones [60, 100, 130]。平衡微调与分类器重训练采用较小 batch size (16) 和较低学习率 (0.01、0.005), 以便在类别不平衡的联合数据上更细粒度地调整分类器, 同时减少对已学权重的扰动。

知识蒸馏。巩固阶段训练 150 轮, 学习率取主训练的 0.1 倍 (0.01), milestones 与衰减策略同分类器扩展阶段。温度 $T = 2$ 使软化后的概率分布保留类间相对关系而不至于过于尖锐; 蒸馏损失权重 $\lambda_{KD} = 1.5$ 在交叉熵与蒸馏项之间取得平衡。

在 WiAR 类增量实验中, 样本被整理为固定长度的 CSI 时序特征, 输入维度为

90×512 ，其中 90 对应 3 个接收天线与 30 个子载波展开后的通道维度，512 为统一后的时间长度。为保持第三章类增量方法结构一致，WiAR 实验同样采用 U-Net 作为骨干网络，但输入通道数调整为 90。与第四章 WiAR 少样本类增量实验不同，本章不对通道维进行重复扩展，而是直接使用 90 通道 CSI 时序表示进行类增量训练。增量阶段采用固定记忆库策略，旧类代表样本与当前新类数据共同参与训练，以保证不同类别阶段之间的可比性。

主要超参数汇总见表 ??。该表主要对应 XRF 主实验的训练配置；WiAR 实验在骨干与输入形状上按 3.3.1 节说明另行设定，但各阶段训练轮次、学习率调度与蒸馏温度等仍与表 ?? 保持一致，以保证可比性。骨干网络采用 UNet 或 ResNet-18：在 XRF 上输入为 270 维 CSI 特征序列，UNet 情形下张量形状为 $(B, 270, L)$ ，经编码—解码与全局池化后由全连接层输出各类 logits；ResNet-18 亦为 1D 时序结构以适配 CSI 输入。骨干选择不改变前述回放、扩展与巩固的三阶段训练流程。骨干对比实验见 3.4 节。

表 3-2 训练超参数

阶段	训练轮数	学习率	学习率衰减	batch size	权重衰减
初始训练	250	0.1	$[80, 150, 200], \times 0.1$	64	5×10^{-4}
分类器扩展	150	0.1	$[60, 100, 130], \times 0.1$	64	2×10^{-4}
平衡微调	10	0.01	—	16	1×10^{-4}
分类器重训练	15	0.005	—	16	1×10^{-4}
知识蒸馏	150	0.01	$[60, 100, 130], \times 0.1$	64	2×10^{-4}

3.3.4 对比方法与基线

为全面评估本文方法，实验在 XRF 与 WiAR 上分别设置对比集合。在 XRF 数据集上，对比方法包括 Finetune 基线、iCaRL^{rebuffi2017icar1}、BiC^{wu2019bic}、UCIR^{hou2019ucir}、SimpleCIL^{zhou2025revisiting}、IL2A^{zhu2021il2a}、CREATE^{chen2025create} 与本文方法。其中 Finetune 为每个增量阶段仅用新类别数据微调、无记忆回放与无知识蒸馏的参照；iCaRL、BiC、UCIR 等为经典类增量学习方法；SimpleCIL 与 IL2A 分别代表预训练极简分类器与双路增强类增量设定；CREATE 为近年从类别表征与混淆抑制角度改进 CIL 的方法，通过类别自编码器与潜空间分离损失增强类间可分性。XRF 实验均采用相同划分、15+10×4 协议、UNet 骨干与软硬件环境。

表 3-3 类增量对比方法概览

方法	年份	出处	类型	使用数据集	主要机制
Baseline	—	基线	直接微调	XRF、WiAR	仅使用新类数据更新
iCaRL	2017	CVPR	回放 + 蒸馏	XRF	Exemplar + 最近类均值
BiC	2019	CVPR	偏差校正	XRF、WiAR	新旧类 logit 偏差校正
UCIR	2019	CVPR	特征蒸馏	XRF	余弦分类器 + 特征约束
SimpleCIL	2025	IJCV	简化基线	XRF、WiAR	预训练表征 + 简单分类器
IL2A	2021	NeurIPS	特征增强	XRF、WiAR	旧类特征分布增强
CREATE	2025	CVPR	混淆抑制型 CIL	XRF	类别自编码器 + 潜空间分离
本文方法	—	本文	回放—扩展—巩固	XRF、WiAR	记忆回放 + 分类器扩展 + 双边蒸馏

3.4 实验结果与分析

3.4.1 评价指标

类增量学习的评估需兼顾“对新类的学习能力”与“对旧类的保持能力”，且推理时模型需在全体已见类别上统一分类，不提供任务标识。实验中采用准确率（Accuracy）、ACCN 与平均准确率（AA）等指标，从不同角度刻画上述能力。

准确率（Accuracy）。各增量阶段结束后，在全体已见类别的测试集上计算分类准确率。测试集覆盖 Session 0 至当前 Session 所学的所有类别，每条样本的预测与真实标签在同一标签空间内比较。设测试样本总数为 N ， $y_{\text{pred}}^{(i)}$ 与 $y_{\text{true}}^{(i)}$ 分别为第 i 个样本的预测标签与真实标签，则

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{I} \left(y_{\text{pred}}^{(i)} = y_{\text{true}}^{(i)} \right) \quad (3-16)$$

式中：Accuracy——全类 Top-1 准确率； $\mathbb{I}(\cdot)$ ——指示函数。

式 (??) 给出会话级准确率在样本上的估计。该指标直接反映模型对所有已学类别的整体判别能力。在类增量设定下，若模型严重遗忘旧类，即使对新类拟合良好，准确率也会因旧类错误而下降；反之，若过度保护旧类而牺牲新类学习，准确率同样受限。因此，准确率是衡量稳定性与可塑性平衡的综合指标。

ACCN。随着增量推进，类别数从 15 增至 55，仅用准确率难以区分两种情形：一

是模型能识别更多类别但准确率有所下降；二是模型仅能识别少量类别但准确率较高。为此引入 ACCN (Accuracy $\times$ Class Number)：设当前已见类别数为 N_{cls} ，则 $\text{ACCN} = \text{Accuracy} \times N_{\text{cls}}$ 。ACCN 将“可识别类别数”与“平均正确率”相乘，若准确率维持不变，ACCN 应随类别数近似线性增长，对应理想增量学习的“扩展而不遗忘”目标。实际中因灾难性遗忘，准确率会随增量阶段下降，ACCN 曲线往往低于理想线，且在中后期出现波动甚至下滑。通过比较不同方法的 ACCN 曲线，可直观判断各方法在增量过程中是否既能扩展类别又保持较高正确率。本文在各对比实验与消融实验中均计算 ACCN，并绘制相应曲线供分析。

此外，为综合衡量模型在整个增量过程中的平均表现，本文计算各阶段准确率的算术平均值，记为平均准确率 (Average Accuracy, AA)。AA 越高，说明模型在从基础阶段到末次增量阶段的整体识别能力越稳定。本章类增量主对比 (表 ??) 中，AA 取 Session 0–Session 4 五个阶段 Top-1 准确率的算术平均；第四章少样本类增量实验中的 AA 定义与该章会话划分一致。

3.4.2 对比实验结果

(1) XRF 数据集对比实验结果。

主对比。表 ?? 列出了 XRF 数据集上 Finetune 基线、iCaRL、BiC、UCIR、SimpleCIL、IL2A、CREATE 与本文方法在 5 个增量阶段上的准确率及各方法的平均准确率 (AA)。

表 3-4 类增量学习方法对比实验 (CNN Top1 准确率, %)

方法	S0	S1	S2	S3	S4	AA
Baseline	89.67	38.84	26.97	21.83	16.25	38.71
iCaRL(2017) ^{rebuffi2017icarl}	90.41	74.09	66.90	63.68	63.49	71.71
BiC(2019) ^{wu2019bic}	86.11	64.91	52.56	50.10	44.35	59.61
UCIR(2019) ^{hou2019ucir}	88.07	77.16	69.24	61.73	63.58	71.96
SimpleCIL(2025) ^{zhou2025revisiting}	90.85	60.80	44.78	37.27	30.52	52.84
IL2A(2021) ^{zhu2021il2a}	90.30	73.31	56.43	48.90	38.21	61.43
CREATE(2025) ^{chen2025create}	87.60	70.31	64.81	62.46	59.17	68.75
本文方法	91.52	80.47	74.24	72.72	73.57	78.50

由表 ?? 可见，不同方法在基础阶段差异相对有限，但随着增量轮次增加，性能分化迅速扩大。Baseline 在首次增量后便出现明显退化，之后继续快速下滑，说明单纯顺序微调难以维持旧类判别边界。相比之下，包含回放、蒸馏或结构扩展机制的方法整体更稳定。本文方法在整个增量过程中始终保持较高水平，尤其在最后阶段仍维持 73.57% 的准确率，表明回放、扩展与巩固三部分能够形成较好的协同作用。各方法在相同数据集与增量划分、相同 CNN Top1 评估与 UNet 骨干下复现；其中 iCaRL、BiC、UCIR 及本文在需要时按各自实现构建 exemplar 记忆 (本文每类 75 个，见 3.2.1 节)；SimpleCIL、IL2A 为文献中代表性的轻量与双路增强基线；CREATE 依据文献与公开复现配置完成适配；其余训练细节依各方法配置。以下分方法分析。

Baseline 在每个增量阶段仅用新类别数据微调模型，无记忆回放与知识蒸馏。Session 0 准确率为 89.67%，学习 15 类时表现良好；自 Session 1 起，随着新类不断加入且旧类数据不可访问，模型对新类的拟合逐步覆盖旧类表征，Session 1 降至 38.84%，Session 4 进一步降至 16.25%。Session 0→4 下降 73.42 个百分点，灾难性遗忘极为严重。该结果印证了 3.1 节所述：若不对增量过程施加额外约束，模型难以在吸收新知识的同时保留旧知识。

iCaRL 通过样本回放与基于 exemplar 的知识蒸馏缓解遗忘。Session 4 准确率为 63.49%，较 Baseline 提升 47.24 个百分点。但从 Session 1 至 Session 4 的曲线看，准确率由 74.09% 降至 63.49%，下降约 10.6 个百分点，说明在类别数持续增加时，单一主干 + 蒸馏的策略仍面临可塑性瓶颈：模型需在固定容量内同时表示 55 类，旧类与新类竞争表示空间。

BiC 引入偏差校正以缓解新旧类 logits 尺度差异，Session 4 为 44.35%，低于 iCaRL 与 UCIR。从各 Session 的走势看，BiC 自 Session 2 起下滑加快（Session 2 为 52.56%，Session 3 为 50.10%），表明其偏差校正对后期类别增多时的 logits 偏移仍不足以应对，旧类保留能力不足。

UCIR 采用无偏对比损失与基于余弦相似性的分类器，在 Session 1-2 表现较好（77.16%、69.24%），高于 iCaRL 与 BiC；但 Session 3 降至 61.73%，Session 4 为 63.58%，出现波动。其设计侧重缓解类别不平衡；在本文 15+10+10+10+10 的长序列增量设置下，中后期准确率出现波动，稳定性不及本文方法。

SimpleCIL^{zhou2025revisiting} 在固定骨干上以类均值等极简方式完成增量。Session 0 为 90.85%，与多数方法接近；自 Session 1 起准确率下降至 60.80%，Session 4 为 30.52%，整体持续下滑，ACCN 亦明显低于本文，反映出在仅靠极简分类头扩展时，旧类判别在增量后期易被新任务主导。

IL2A^{zhu2021il2a} 将特征级与样本级双路增强用于缓解遗忘。Session 0 为 90.30%；Session 1-4 依次为 73.31%、56.43%、48.90%、38.21%，末阶段优于 SimpleCIL 与 Baseline，但仍明显低于本文在回放—扩展—巩固下的整体表现。

CREATE^{chen2025create} 在 XRF 上 Session 0-4 依次为 87.00%、70.31%、64.81%、62.46%、59.17%。末次增量阶段 CREATE 准确率为 59.17%，低于本文方法的 73.57%。从结果上看，CREATE 在通用视觉类增量学习中通过类别自编码器与潜空间分离缓解类别混淆的思路，在迁移至 Wi-Fi CSI 时序输入时，末阶段准确率仍低于本文在回放—扩展—巩固框架下的表现。可能的原因包括：图像域与 CSI 域在特征统计与判别结构上存在差异，以及本文在记忆回放、冻结骨干下的分类器扩展与双边知识蒸馏等环节对长序列增量场景中的旧类保持与新类接入做了针对性组合。上述解释需结合更多消融与可视化证据进一步验证。

本文方法在 Session 4 达到 73.57%，在表 ?? 中高于所列各对比方法。相较于 Baseline，性能下降仅 17.95 个百分点，降幅缩小 55.47 个百分点；相较于 iCaRL、BiC、UCIR，Session

4 分别提升 10.08、29.22、9.99 个百分点；相较于 SimpleCIL、IL2A、CREATE，Session 4 分别提升 43.05、35.36、14.40 个百分点。从各 Session 的走势看，本文方法在 Session 1-2 保持较高准确率（80.47%、74.24%），Session 3 略降至 72.72%，Session 4 回升至 73.57%。Session 4 相较 Session 3 出现小幅回升。结合后续消融结果推测，这一现象可能与分类器扩展后的再平衡及蒸馏巩固过程有关，但其具体贡献仍需结合更细粒度实验进一步验证。样本重放对本文性能的贡献见 3.4.3 节。

从机制层面归纳，表 ?? 所呈现的分化可概括为三类因素：其一，Baseline 仅用新类数据更新全参数，旧类决策边界缺乏持续监督，因而在 CSI 时序特征上表现为快速遗忘；其二，iCaRL、BiC、UCIR 等虽引入回放、偏差校正或特征约束，但在长序列增量与新旧样本数量严重失衡的条件下，仍易受 logits 尺度偏移、表示容量竞争与时序模式差异等因素影响，中后期性能波动或下滑相对更为明显；其三，本文在冻结骨干的前提下以扩展分类器接纳新类，并以记忆样本与双边蒸馏将扩展阶段知识回写到统一主干，使多阶段更新在「旧类边界可回顾、新类接入有通道、跨阶段知识可迁移」三方面形成互补。结合 XRF 与 WiAR-16 两组实验可见，该流程在不同类别规模与 CSI 数据分布下均能保持相对稳定的增量表现，但并不能据此认为已穷尽所有环境扰动与协议变体。

图 ?? 给出各方法的 ACCN 曲线。




图 3-4 各方法 ACCN 曲线对比（含 CREATE）

理想曲线假定准确率维持 Session 0 水平不变，ACCN 随类别数线性增长；Baseline 的 ACCN 在 Session 1 后骤降，之后持续低位；iCaRL、BiC、UCIR 的曲线在中后期出现不同程度下滑或波动，均明显低于理想线；SimpleCIL、IL2A、CREATE 的 ACCN 随增量推进整体低于本文。依据表 ??，Session 4 时 CREATE 的 ACCN 为 $59.17 \times 55 = 3254.35$ ，亦低于本文。本文方法的 ACCN 在 Session 4 时为 $73.57 \times 55 = 4046.35$ ，高于 iCaRL 的 $63.49 \times 55 = 3491.95$ 、IL2A 的 $38.21 \times 55 = 2101.55$ 与 SimpleCIL 的 $30.52 \times 55 = 1678.60$ ，亦高于 CREATE 的上述 ACCN，与理想曲线的差距小于多数基线。图 ?? 给

出了含 CREATE 在内的各方法 ACCN 曲线，与表 ?? 中各会话 Top-1 准确率一致。综合表 ?? 与图 ??，在统一数据与划分下，本文方法在末阶段整体准确率与 ACCN 优于表中所列其余方法；结合 3.4.3 节关于样本重放的消融，可进一步理解不同训练机制下的差距来源。

(2) WiAR 数据集对比实验结果。

表 3-5 WiAR-16 数据集上的类增量学习对比实验 (CNN Top1 准确率, %)

方法	Session 0	Session 1	Session 2	Session 3	Session 4	Session 5	AA
Baseline	96.30	22.22	25.56	16.67	19.84	8.33	31.52
BiC(2019) ^{wu2019bic}	16.67	12.50	10.00	8.33	7.14	5.56	10.03
SimpleCIL(2025) ^{zhu2025revisiting}	96.30	79.17	63.33	62.04	53.97	45.83	66.78
IL2A(2021) ^{zhu2021il2a}	96.30	68.06	46.67	43.52	38.10	31.25	54.13
本文方法	98.83	88.89	73.33	68.52	69.84	64.58	77.33




图 3-5 WiAR-16 类增量各会话 Top-1 准确率对比

表 ?? 与图 ?? 给出了 WiAR 数据集上的类增量对比结果。可观察到，Baseline 在 Session 0 取得 96.30% 的准确率，但随着新类别持续加入，其末次阶段准确率下降至 8.33%，说明仅依赖当前阶段数据进行微调会造成严重灾难性遗忘。BiC 在该设置下整体表现较弱，末次阶段准确率为 5.56%，说明偏差校正机制在该 WiAR 输入与训练设置下未能有效维持新旧类平衡。SimpleCIL 和 IL2A 相较 Baseline 与 BiC 表现更稳定，末次阶段准确率分别为 45.83% 和 31.25%，但随着增量阶段推进仍存在明显性能下降。相比之下，本文方法在 WiAR-16 设置下取得 77.33% 的平均准确率和 64.58% 的末次阶段准确率，分别高于 SimpleCIL 10.55 个百分点和 18.75 个百分点。该结果说明，回放—扩展—巩固框架不仅适用于 XRF 的复杂多类别场景，也能够类别规模较小、数据分布不同的 WiAR 数据集上保持较好的增量稳定性。结合 XRF 与 WiAR 两组实验表明，所提方法对不同 Wi-Fi CSI 数据集具有一定适用性。

骨干网络对比。表 ?? 对比了 ResNet-18 与 UNet 两种骨干在同等实验设置下的表

现。两者均为 1D 时序结构,可适配 270 维 CSI 特征输入,区别在于特征提取方式:ResNet 通过残差块堆叠进行层级特征抽取;UNet 采用编码器—解码器结构,在降采样与上采样过程中保留多尺度信息。

从表 ?? 可见,UNet 在各 Session 上均优于 ResNet。Session 0 时,UNet 为 91.52%, ResNet 为 89.37%,相差 2.15 个百分点;随增量推进,差距逐步扩大,Session 2 为 74.24% vs 62.00% (差 12.24), Session 4 为 73.57% vs 58.41% (差 15.16)。Session 0→4 的准确率下降幅度,ResNet 为 30.96 个百分点,UNet 为 17.95 个百分点,UNet 的下降更缓。图 ?? 的 ACCN 曲线同样显示,UNet 在各阶段的 ACCN 均高于 ResNet,且与理想曲线的差距更小。从 Session 3 与 Session 4 的对比看,ResNet 出现 61.40%→58.41% 的下降,UNet 则出现 72.72%→73.57% 的小幅回升,UNet 在后期的表现更为稳定。

上述差异可从 CSI 信号特性与网络结构的关系理解。Wi-Fi CSI 为时序信号,不同动作对应不同的时变模式,多尺度时序特征(如短时突变与长时趋势)对区分动作均有贡献。UNet 的编码—解码结构通过跳跃连接保留多尺度特征,有利于捕获 CSI 中的粗细粒度模式;ResNet 虽具备深层表示能力,但在 1D 时序上对多尺度信息的显式建模较弱。此外,增量学习中,骨干需为不断扩大的类别空间提供可区分的特征;本文结果表明,UNet 在当前 Wi-Fi CSI 时序建模任务中具有更稳定的增量表现;至于这一优势是否主要来自其多尺度建模能力,还需要结合特征可视化或更细粒度的模块消融进一步分析。从参数量与计算开销看,两种骨干在同一量级,选择 UNet 不会显著增加部署成本,却在 Session 4 带来约 15 个百分点的准确率提升,性价比较高。基于上述结果,后续主对比与消融实验均以 UNet 为骨干。

表 3-6 骨干网络对比实验 (%)

骨干	Session 0	Session 1	Session 2	Session 3	Session 4
ResNet	89.37	71.47	62.00	61.40	58.41
UNet	91.52	80.47	74.24	72.72	73.57




图 3-6 骨干网络 ACCN 曲线对比

KD 与 BKD 对比。表 ?? 对比了标准知识蒸馏 (KD) 与双边知识蒸馏 (BKD) 在知识巩固阶段的效果。两者均以分类器扩展后的网络为教师、以新初始化的单主干为学生, 训练目标均为交叉熵与蒸馏损失的组合; 区别在于 BKD 除 logit 级蒸馏外, 增加特征级蒸馏项, 在表示空间上引导学生对齐教师。

在本文设置中, 记忆库每类仅保留 75 个 Exemplar, 而新任务每类通常有数百个样本。联合训练集 $\hat{\mathcal{D}}^t = \mathcal{D}^t \cup \mathcal{E}$ 中, 新类样本占比远高于旧类, 导致教师模型的 logits 与预测分布自然偏向新类。标准 KD 仅最小化师生 logits 的 KL 散度, 对中间表征的约束不足; BKD 通过式 (??) 在特征空间施加对齐损失, 使学生表征更贴近教师, 从而在增量后期对旧类保留更充分。随着增量推进, 旧类数增多而每类 Exemplar 数固定, 特征级蒸馏的收益在 Session 2 之后愈发明显。

从不同巩固方式的结果表明, KD 与 BKD 在基础阶段差异较小, 但随着增量会话推进, BKD 的优势逐步显现。进入后续阶段后, BKD 始终保持更高准确率, 说明在类别不断扩展、样本分布持续变化的条件下, 双边蒸馏更有利于同时兼顾新类适应与旧类保持。因此, 本文后续实验统一采用 BKD 作为默认知识巩固策略。Session 各阶段的定量对比见表 ??, ACCN 曲线见图 ??。

表 3-7 知识蒸馏方式对比 (%)

巩固方式	Session 0	Session 1	Session 2	Session 3	Session 4
KD	91.19	78.13	72.78	72.42	70.20
BKD	91.52	80.47	74.24	72.72	73.57




图 3-7 KD 与 BKD 的 ACCN 曲线对比

3.4.3 消融实验

为验证各模块的贡献, 本节在保持其他设置不变的前提下, 依次对样本重放、分类器扩展组件及知识蒸馏巩固进行消融。

样本重放。类增量学习中, 旧类数据通常不可访问, 模型若仅用新类数据训练, 会因参数更新覆盖旧类表征而导致灾难性遗忘。样本重放通过在内存中保留少量旧类代

表样本 (Exemplar)，在每轮增量训练中将之与新类数据联合使用，使模型在拟合新类的同时仍能接触到旧类样本，从而维持对旧类决策边界的记忆。本文采用 3.2.1 节所述的类均值最近邻迭代选择 (Herding) 构建 Exemplar，每类保留 75 个样本；记忆库规模随类别数线性增长，在 55 类时约 4125 条，在可接受范围内。表 ?? 对比了有无样本重放时的表现。

样本重放的作用主要体现在对旧类信息的持续保留上。实验结果表明，是否使用重放对基础阶段影响很小，但进入增量阶段后差异迅速拉开。无重放设置下，模型性能在首次增量后便明显下降，随后继续快速衰减；而引入记忆样本后，模型在后续各阶段均能维持较高准确率。这说明，旧类代表样本在增量训练中具有基础支撑作用，缺少这部分信息时，模型更新会更容易偏向新类别，进而加剧灾难性遗忘。具体数值对比见表 ?? 与图 ??。结合表 ?? 中 Baseline（无回放、无蒸馏）与本文方法的对比，样本重放是本文方法取得较好性能的基础条件之一。若进一步增加每类 Exemplar 数量（如 100 或 150），理论上可带来额外收益，但会增大内存占用；本文固定采用每类 75 个 Exemplar，该设置能在不显著增加存储开销的前提下维持可接受的增量性能；其是否为最优记忆规模，仍有待进一步实验比较。




图 3-8 样本重放消融的 ACCN 曲线

表 3-8 样本重放消融实验 (%)

是否回放	Session 0	Session 1	Session 2	Session 3	Session 4
否	91.33	42.00	34.97	29.40	23.19
是	91.52	80.47	74.24	72.72	73.57

分类器扩展组件。3.2.2 节在分类器扩展阶段依次采用了平衡微调与分类器重训练，旨在缓解联合训练集 $\hat{\mathcal{D}}^t$ 中新旧类样本数量不平衡带来的 logits 偏置。为考察两者的贡献，在保留样本重放与知识蒸馏的前提下，分别移除其中一项，结果见表 ??。

无平衡微调时，Session 4 准确率为 72.36%，完整方法为 73.57%，低 1.21 个百分点；无分类器重训练时，Session 4 为 72.14%，较完整方法低 1.43 个百分点。与去除平衡微

调、去除分类器重训练或去除知识巩固的设置相比，完整方法在各阶段整体表现更稳定。这表明本文框架并非依赖单一模块获得提升，而是通过多个环节共同作用来抑制性能衰减：分类器扩展负责接纳新类，平衡微调用于缓解样本不均衡带来的偏置，而知识巩固进一步降低增量更新中的旧类退化（知识巩固的对照见表 ??）。从各 Session 的走势看，无平衡微调在 Session 2 略高于完整方法（75.11% vs 74.24%），但 Session 3-4 持续下降；无分类器重训练在 Session 2 略低（72.68% vs 74.24%），整体趋势相近。平衡微调与分类器重训练的设计意图仍分别体现在 batch 内梯度均衡与联合数据再巩固上；在当前数据划分与记忆库规模下，二者对 Session 4 的边际影响相对有限，主体收益仍来自“冻结骨干+分类器扩展+蒸馏巩固”框架。考虑到不同随机种子下结果存在波动，本文不对这两项组件的细微差异作进一步因果归因。

表 3-9 分类器扩展组件消融实验（%）

实验配置	Session 0	Session 1	Session 2	Session 3	Session 4
无平衡微调	91.19	80.22	75.11	73.16	72.36
无分类器重训练	91.07	80.58	72.68	73.07	72.14
完整方法	91.52	80.47	74.24	72.72	73.57

知识巩固。为验证知识巩固的必要性，在其余模块不变的前提下设置有无巩固对照（见表 ??）。该步骤将分类器扩展阶段分散于教师网络中的判别能力，通过教师—学生双边蒸馏整合至单一主干，再由学生作为下一增量阶段的基模型；师生同构、参数量约 20.76M，重在跨阶段知识整合而非压缩模型规模。

不进行知识巩固时，分类器扩展阶段学到的新旧类知识无法通过软标签传递至独立的学生网络，模型在下一增量阶段直接沿用扩展后的教师参数继续训练。实验结果显示，这种“无巩固”配置导致灾难性的性能坍塌：Session 0 时准确率为 91.30%，与完整方法的 91.52% 接近；但自 Session 1 起骤降至 3.87%，Session 2-4 进一步跌至 2.86%、2.27%、1.82%。Session 4 时模型几乎完全丧失判别能力，55 类上仅 1.82% 的准确率接近随机猜测水平（ $1/55 \approx 1.82\%$ ），表明无巩固时模型输出的类别分布极度偏斜，仅能识别最近学习的少数类别。

引入知识巩固后，Session 1 准确率为 80.47%，Session 4 为 73.57%，与无巩固版本在 Session 4 相差 71.75 个百分点。这一巨大差距源于蒸馏巩固的两重作用：其一，教师通过软标签传递类间相对置信关系（即 Hinton 所述的“暗知识”），使学生在仅用交叉熵监督难以学到的旧类间细微差异上获得额外指导；其二，特征级蒸馏（BKD）迫使学生的中间表征对齐教师，相当于对学生的表示空间施加正则化约束，避免其在后续增量中偏离已学到的判别结构。从 Session 3 与 Session 4 的对比看，有巩固时准确率从 72.72% 小幅回升至 73.57%，在后期类别数较多时，巩固阶段的蒸馏可能起到了更稳定的正则化作用，但具体机制仍需进一步分析。

图 ?? 的 ACCN 曲线同样表明，无巩固时 ACCN 自 Session 1 起几乎为零并持续贴近横轴，有巩固时则在各阶段保持稳定增长，二者差距悬殊。综合表 ?? 可知，知识巩

固是本文框架中不可或缺的核心组件，其本质是通过教师—学生蒸馏实现跨增量阶段的知识整合，确保模型在每轮扩展后仍能保留对全体已见类别的判别能力。




图 3-9 知识巩固消融的 ACCN 曲线

表 3-10 知识巩固消融实验 (%)

是否巩固	参数量	Session 0	Session 1	Session 2	Session 3	Session 4
否	20.76M	91.30	3.87	2.86	2.27	1.82
是	20.76M	91.52	80.47	74.24	72.72	73.57

3.5 本章小结

本章面向新增类样本相对充足的 Wi-Fi CSI 类增量动作识别场景，提出了回放—扩展—巩固框架。该框架通过类均值选样构建记忆库，在冻结骨干网络的基础上扩展分类器以接入新类别，并利用教师—学生双边知识蒸馏完成新旧类知识巩固。实验结果表明，在 XRF 的 15+10×4 类增量设置下，本文方法末次增量阶段准确率达到 73.57%；在 WiAR-16 设置下，平均准确率和末次阶段准确率分别达到 77.33% 和 64.58%，整体优于主要对比方法。消融实验进一步说明，样本重放、知识巩固、UNet 骨干与双边知识蒸馏均对增量稳定性具有积极作用。总体来看，所提方法能够在类别持续扩展过程中较好兼顾新类学习与旧类保持，为新增类样本充足条件下的 Wi-Fi 感知模型持续更新提供了有效方案。

4 面向 Wi-Fi 信号动作识别的少样本类增量学习方法研究

4.1 问题概述

本节面向基于 Wi-Fi CSI 信号的室内动作识别任务，给出少样本类增量学习的形式化定义，分析其核心挑战与研究的现实意义，并阐明本文的研究思路。在类别扩展之外，少样本类增量学习要求每个增量会话仅能访问极少量的新类别样本，使得模型在应对灾难性遗忘的同时还需应对样本稀缺导致的过拟合，难度高于第三章所探讨的类增量学习（CIL）。

因此，本章并非简单延续第三章的回放—扩展—巩固流程，而是在旧类数据不可完整回放、新类样本极少的条件下重新设计特征表示与分类机制。这种设置更接近实际 Wi-Fi 感知系统中新增动作难以大量采集的场景，也进一步检验模型在低标注成本条件下的持续更新能力。

对于 Wi-Fi CSI 室内动作识别任务，新增类别往往难以在短时间内采集到大量标注样本。例如，康复动作、个性化家庭交互动作或特定场景下的新型行为通常只能获得极少量样本。在第三章所研究的类增量学习（CIL）场景中，每个增量任务仍可访问充足的新类样本，模型能够借助样本重放与知识蒸馏维持性能；而在实际部署中，新类别的标注往往远不充分，CIL 的假设难以满足。少样本类增量学习（FSCIL）正是面向这一更为苛刻的条件：增量阶段每类仅有极少量样本（如 1-shot），模型需在样本稀缺与类别扩展的双重约束下完成学习。在 Wi-Fi CSI 场景下研究 FSCIL，不只是为了降低标注成本，更在于提升模型对动态类别集合的持续适应能力。

本任务的困难主要来自三个方面。第一，增量阶段每个新类别仅含极少量样本，导致类别原型对噪声和个体差异较为敏感，模型难以从有限监督信息中建立稳定的类别表示。第二，模型需在持续引入新类别的同时保持对旧类别的识别能力，然而在缺乏旧类数据访问的条件下，新类学习容易覆盖旧类表征，灾难性遗忘问题在少样本场景下更为突出。第三，Wi-Fi CSI 具有明显的时序特性，不同动作在短时与长时尺度上的差异较大，若表征能力不足，少样本条件下更容易出现新旧类别混淆。上述三方面困难相互交织，使得 FSCIL 的模型设计与优化较 CIL 更为困难。

第三章在「新增类样本相对充足」的类增量设定下，通过记忆回放、冻结骨干下的分类器扩展与知识巩固，给出了面向 Wi-Fi CSI 的一条可行技术路线。然而在实际感知系统中，新动作类别往往只能获得极少标注，若仍沿用第三章的样本条件假设，则难以稳定建立新类判别边界。基于此，本章在继承「类别集合持续扩展」这一核心矛盾的前提下，进一步研究少样本类增量学习：在增量侧每类仅提供极少监督的前提下，引入时序增强、类别关系建模与双分类器融合，以提升新类适应能力并减缓旧类退化。

4.1.1 任务定义

第四章研究的是面向 Wi-Fi CSI 室内动作识别的少样本类增量学习问题。与第三章中的类增量学习相比，该任务在类别持续扩展之外，还进一步限制了增量阶段每个新类别所能提供的标注样本数量。因此，模型在后续会话中不仅要识别此前未见的新类别，还要在极少监督条件下形成对这些类别的有效表示，并尽量避免旧类别判别能力明显退化。

从任务设定上看，FSCIL 可以理解为在类增量学习框架中进一步加入「新类样本极少」的限制条件^{zhou2024cil,tian2024fscilsurvey,tao2020topic}。基础会话通常包含较充足的基础类别样本，用于获得初始表征能力；进入后续增量会话后，模型每次只接收少量新类别样本，且训练完成后需要在所有已见类别范围内统一测试。与任务增量学习或域增量学习不同，本文关注的并不是任务标识已知条件下的分任务判别，也不是同类别在不同域之间的适应，而是在统一类别空间中逐步接纳新类并保持旧类识别能力^{zhou2024cil,tian2024fscilsurvey,tao2020topic}。表 ?? 对比了几种常见持续学习设定在训练数据和测试范围上的差异。

表 4-1 FSCIL、CIL 与 TIL 等常见持续学习设定对比

任务类型	基础会话训练数据	增量会话训练数据	测试范围
少样本类增量学习 (FSCIL)	基础类别充足样本	新增类别有限样本	所有已知类别
类增量学习 (CIL)	基础类别充足样本	新增类别充足样本	所有已知类别
任务增量学习 (TIL)	基础类别充足样本	新增类别充足样本	已知任务的已知类别

在本文设定中，少样本类增量学习由基础会话和若干增量会话组成。基础会话用于学习初始类别的稳定表示；自第一个增量会话开始，模型每次仅利用当前到达的少量新类样本进行更新，而此前会话的训练数据默认不再完整可用。这样设置更接近无线感知系统在长期运行中的实际情况：新类别会不断出现，但每个阶段可采集到的标注样本往往十分有限。因此，FSCIL 的关键不只是「学会新类」，更在于如何在极少样本条件下兼顾新类适应与旧类保持。

沿用 FSCIL 领域常用的符号体系^{tian2024fscilsurvey}，将少样本类增量学习任务形式化如下。设存在一个 m 步的 FSCIL 任务，用 $\{D_{\text{train}}^{(0)}, D_{\text{train}}^{(1)}, \dots, D_{\text{train}}^{(m)}\}$ 和 $\{D_{\text{test}}^{(0)}, D_{\text{test}}^{(1)}, \dots, D_{\text{test}}^{(m)}\}$ 分别表示会话 $\{0, 1, \dots, m\}$ 的训练集与测试集。对会话 j ，其训练集 $D_{\text{train}}^{(j)}$ 对应标签空间 $\mathcal{Y}_j$ ，不同会话的标签空间互不相交，即 $\mathcal{Y}_a \cap \mathcal{Y}_b = \emptyset$ ($a \neq b$)。基础会话 $D_{\text{train}}^{(0)} = \{(x_i, y_i)\}_{i=1}^{n_0}$ 是一个类别数量较多的数据集，其中每个数据类别均包含足够多的样本用于训练， $x_i \in \mathbb{R}^D$ 为类别 $y_i \in \mathcal{Y}_0$ 的一个数据样本， $\mathcal{Y}_0$ 对应基础阶段的标签空间。第 j 个增量会话的 $D_{\text{train}}^{(j)}$ 以 N-way K-shot 形式组织：包含 N 个类别，每类 K 个训练样本。面对新数据集 $D_{\text{train}}^{(j)}$ ，模型需在学习新类别的同时保持对旧类别的性能，即最小化所有已见类别上的期望风险：

$$\mathbb{E}_{(x,y) \sim D_{\text{train}}^{(0)} \cup \dots \cup D_{\text{train}}^{(j)}} \left[\ell \left(f \left(x; D_{\text{train}}^{(j)}, W^{j-1} \right), y \right) \right] \quad (4-1)$$

式中： $D_{\text{train}}^{(j)}$ ——会话 j 的训练数据； W^{j-1} ——会话 $j-1$ 结束时的模型参数。

式 (??) 刻画在可访问全部已见训练数据这一理想条件下、FSCIL 在会话 j 上应追求的风险形式，用于与「旧会话数据不可得、仅能基于当前支持集与历史参数更新」的实际训练目标相对照。该式给出理想优化方向；在实际训练中，由于旧会话数据不可访问，只能基于当前支持集与历史模型参数近似实现。在测试阶段，模型将在所有已见类别上进行评估：对于会话 j ，其测试数据为 $\{D_{\text{test}}^{(0)}, D_{\text{test}}^{(1)}, \dots, D_{\text{test}}^{(j)}\}$ ，对应的标签空间为 $\mathcal{Y}_0 \cup \mathcal{Y}_1 \cup \dots \cup \mathcal{Y}_j$ 。

在本文实验中，以 XRF 数据集构造上述 FSCIL 主实验场景；另在 WiAR 公开数据集上开展 WiAR16 式少样本类增量对比，用于在另一公开 Wi-Fi 动作识别数据集上补充检验所提方法在较小类别规模与不同 CSI 数据分布下的适用性（详见 4.3.1 节）。XRF 数据集包含 55 类室内动作，对应 Wi-Fi CSI 信号经预处理后的 270 维 $\times$ 1000 长度时序特征。按本研究的实验配置，将数据划分为 1 个基础会话与 5 个增量会话：基础会话使用前 30 类进行充分训练，随后的 5 个增量会话每会话引入 5 个新类别，即 5-way 1-shot 设定，每类仅有 1 个训练样本。训练集与测试集按 7:3 划分。整体流程如图 ?? 所示。




图 4-1 面向 Wi-Fi CSI 动作识别的少样本类增量学习系统流程

4.1.2 研究思路

传统 CIL 方法难以直接迁移到本任务，关键原因不在于类别是否持续增加，而在于增量阶段每类仅有极少量样本，导致新增类别的表示难以稳定建立。CIL 中常用的样本回放与知识蒸馏均依赖充足的新类数据或旧类 Exemplar，在 1-shot 条件下效果大打折扣；新类分类器因监督信息不足而区分性较弱，旧类表征也容易在增量过程中受到扰动。

现有少样本类增量学习研究中，较常见的一类思路是在后续增量阶段不断修正模

型，以减弱新类学习对旧类知识的冲击。此类方法通常通过蒸馏约束、回放机制或参数正则化等手段控制模型更新幅度，使新阶段模型尽量继承已有类别的判别信息。其优点在于能够直接围绕“防遗忘”目标展开设计，但也存在明显局限：如果基础阶段或早期增量阶段形成的表示本身不够稳健，那么这种缺陷会在后续更新中被持续带入；同时，频繁依赖复杂的阶段性修正，也会带来额外训练开销，并可能因为样本选择偏差或约束强度不当而影响新类适应效果。

与其在每个增量阶段反复补偿旧知识，不如在模型初始设计时就考虑未来类别扩展需求，为后续更新预留更充足的表示空间。这一思路更强调模型对未来任务的可扩展性，即在基础阶段通过优化特征结构与判别方式，使模型在后续面对新类别时具有更好的适应基础。基于这种考虑，本文提出了一种结合时序增强与图注意力的少样本类增量学习方案，如图 ?? 所示。该方法在基础会话阶段重点提升特征表达与分类器结构的可迁移性，从而为后续少样本增量更新提供更稳健的支撑，并兼顾当前识别性能与后续扩展能力。

近年来视觉领域的代表性 FSCIL 工作既包括侧重增量阶段关系建模与上下文传播的图结构方法（如 CEC^{zhang2021cec}），也包括在基础阶段显式强调前向兼容性、通过虚拟原型等为后续新类预留嵌入空间的 FACT^{zhou2022fact}，以及在显式记忆与计算约束下利用高维原型更新的 C-FSCIL^{hersch2022cfscil}，以及通过动态可训练网络与正交分解实现旧类特征恢复与嵌入空间优化的 DyCR^{pan2025dyer} 等。上述方法多在自然图像上验证，与 Wi-Fi CSI 时序模态存在域差异；本文在承接「基础阶段前向设计、增量阶段抗遗忘」这一主线的时候，以多尺度时序表征与图—双分类器协同适配 CSI 动作识别，并在统一协议下与文献方法进行复现对比（见 4.3–4.4 节）。

具体而言，本文方案从特征表示与分类器设计两方面应对 FSCIL 挑战。在特征表示方面，针对 Wi-Fi CSI 的时序特性，引入多尺度时序编码与时序注意力融合模块，捕捉不同时间尺度的动作模式（短期、中期、长期），提升在少样本下的特征判别力；在分类器设计方面，在增量阶段利用图注意力传播类别间上下文信息（继承 CEC^{zhang2021cec} 的图注意力机制并增加时序关系建模），结合双分类器架构（继承 CLOM^{zou2022clom} 的设计）缓解类别级过拟合。整体上，本方案融合了特征与特征空间方法（多尺度时序编码、时序注意力融合）与动态网络结构方法（图注意力），并辅以双分类器约束，在兼顾稳定性与可塑性的同时，适配 Wi-Fi CSI 这一时序模态的少样本类增量学习需求。以下各小节将依次阐述上述模块的设计与实现。

本章创新点概括如下：

（1）面向 Wi-Fi CSI 少样本类增量动作识别，将多尺度时序编码、时序注意力融合、增强图注意力与双分类器融合组织为「时序增强—关系建模—双分类融合」的整体方案，使极少监督下的特征学习与类别扩展在统一网络结构中衔接。

（2）利用多尺度一维卷积与时序自注意力显式刻画 CSI 序列在短、中、长尺度上的动作模式差异，并通过位置编码保留时间顺序，以缓解 1-shot 条件下原型估计对局部

噪声过于敏感的问题。

(3) 在增量阶段以图注意力在类别节点间传播上下文，并以主分类器与域内分类器的加权融合抑制新旧类 logits 偏置与类别级过拟合，从而在「新类样本极少、旧类数据不可完整回放」的约束下提升判别边界的稳定性。需要说明的是，上述设计旨在改善既定协议下的平均与末会话表现，并不声称已覆盖所有少样本增量场景。以下各小节将依次阐述上述模块的设计与实现。

4.2 方法概述

本文提出的少样本类增量学习方案由四个核心模块串联而成：多尺度时序编码器负责从原始 Wi-Fi CSI 时序数据中提取多尺度特征；时序注意力融合模块对时序特征进行自注意力建模与全局聚合；增强图注意力网络在少样本增量模式下传播类别间的上下文信息；双分类器架构则通过主分类器与域内分类器的加权融合缓解类别级过拟合。整体数据流为：输入 $\mathbf{x} \in \mathbb{R}^{270 \times 1000}$ 经多尺度时序编码得到 512×100 的时序特征，再经时序注意力融合得到 512 维的全局嵌入，最后经双分类器输出各类别的 logits。在少样本增量阶段，图注意力网络作用于原型与查询特征，以增强类别间关系建模。

与 FACT^{zhou2022fact} 在基础会话中通过虚拟原型挤压已知类嵌入、为后续新类预留空间的做法不同，本文面向 CSI 时序输入，以多尺度一维卷积与位置编码下的时序自注意力显式刻画动作在短、中、长尺度上的模式；与 C-FSCIL^{hersch2022cfscil} 侧重外显记忆与高维原型更新的路线相比，本文在增量阶段采用图注意力在类别节点间传播上下文，并以双分类器融合抑制 1-shot 原型过拟合，实现上与 CEC/CLOM 类似，均采用「冻结骨干、更新分类器」的训练流程。

训练与推理流程。在基础会话（Session 0），多尺度时序编码器、时序注意力融合模块与双分类器均参与端到端训练，采用交叉熵损失作为优化目标。设双分类器融合后的 logits 为 $\mathbf{o} \in \mathbb{R}^C$ ，则基础训练阶段的损失函数为：

$$\mathcal{L}_{\text{base}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(o_{y_i})}{\sum_{c=1}^C \exp(o_c)} \quad (4-2)$$

式中： $\mathcal{L}_{\text{base}}$ ——基础会话平均交叉熵损失； o_c ——融合 logits $\mathbf{o}$ 中第 c 类分量。

式 (??) 给出 Session 0 端到端训练所采用的分类目标。图注意力网络主要在少样本增量阶段参与原型与查询特征之间的关系传播。基础会话阶段的训练重点放在多尺度时序编码器、时序注意力融合模块与双分类器上；图注意力网络不接入 Session 0 的分类主路径，其参数保持网络默认初始化，在进入增量阶段后于 N-way K-shot 计算中参与前向，以增强少样本条件下的类别关系建模。优化器为 SGD（动量 0.9、Nesterov、权重衰减 5×10^{-4} ），多尺度编码器与双分类器使用基础学习率，时序注意力融合模块使用较小学习率以稳定训练。基础会话结束后，采用平均嵌入策略初始化分类器权重，随后进入增量会话。在增量会话中，默认不进行编码器微调（与 CEC/CLOM 策略一致），

仅根据支持集样本提取特征并更新分类器权重；图注意力网络在计算 N-way K-shot 的 logits 时参与前向传播。各模块的设计动机、数学形式与实现细节如下。本文方法的整体架构如图 ?? 所示。




图 4-2 本文少样本类增量学习方法整体架构

4.2.1 多尺度时序编码器

Wi-Fi CSI 信号为随时间变化的时序数据，不同室内动作在不同时间尺度上呈现不同模式。短期模式反映动作的瞬间变化，例如手势的快速挥动、身体的轻微晃动，其时间尺度通常在数十毫秒至百毫秒量级；中期模式反映单个动作的完整周期，如一次完整的举手或蹲起，时间尺度在数百毫秒量级；长期模式则反映整个动作序列的宏观形态，如走步与跑步在整体节奏与幅度上的差异，时间尺度可达数百毫秒甚至更长。例如，快速挥手的识别更依赖局部瞬时突变，而行走与跑步的区分则需要关注整体节奏与幅度。若仅使用单一尺度的卷积核，感受野固定，难以同时捕捉上述多尺度信息，在少样本条件下会导致特征判别力不足。为此，本文设计了多尺度时序编码器，通过三个并行的一维卷积分支分别提取短期、中期与长期特征，再经拼接与融合得到统一的多尺度表示。

设输入为 $\mathbf{x} \in \mathbb{R}^{B \times 270 \times 1000}$ ，其中 B 为批大小，270 为 CSI 子载波或特征维度，1000 为时间步数。一维卷积在时间维度上滑动，每个分支的输出在时间维经自适应平均池化统一为 100 个时间步，以便后续融合与时序注意力处理。三个编码分支的配置如下。

短期编码器：使用 kernel size 为 50、stride 为 10 的一维卷积，padding 设为 25（即 $\lfloor \text{kernel}/2 \rfloor$ ）以保持时间维长度，将 270 维输入映射为 128 维。该分支每 10 个时间步采样一次，窗口覆盖 50 个时间步，可捕捉局部快速变化。经批归一化、ReLU 与 AdaptiveAvgPool1d(100) 后输出形状为 $B \times 128 \times 100$ 。

中期编码器：使用 kernel size 200、stride 50、padding 100 的一维卷积，输出 256 维。该分支每 50 个时间步采样一次，窗口覆盖 200 个时间步，可捕捉单个动作周期的模式。

经批归一化、ReLU 与自适应平均池化后输出形状为 $B \times 256 \times 100$ 。

长期编码器：使用 kernel size 500、stride 100、padding 250 的一维卷积，输出 256 维。该分支每 100 个时间步采样一次，窗口覆盖 500 个时间步（即整个序列的一半），可捕捉整体动作的宏观形态。经批归一化、ReLU 与自适应平均池化后输出形状为 $B \times 256 \times 100$ 。

三路特征在通道维度拼接得到 $B \times 640 \times 100$ ，再经 1×1 卷积（即逐点卷积）、批归一化与 ReLU 融合为 $B \times 512 \times 100$ 的时序特征。多尺度时序编码器的输出可写为：

$$\mathbf{H} = \text{Fusion}\left(\text{Concat}(\phi_{\text{short}}(\mathbf{x}), \phi_{\text{mid}}(\mathbf{x}), \phi_{\text{long}}(\mathbf{x}))\right) \in \mathbb{R}^{B \times 512 \times 100} \quad (4-3)$$

式中： $\mathbf{H}$ ——多尺度时序编码器输出； ϕ_{short} 、 ϕ_{mid} 、 ϕ_{long} ——短、中、长尺度卷积分支。

式 (??) 将三尺度特征融合为统一时序表示。该模块使模型能同时利用不同时间尺度的动作信息，为后续时序注意力与分类提供更丰富的表示基础；在基础训练阶段，多尺度编码器与后续模块一起端到端训练，学习对不同尺度模式的最优组合。多尺度时序编码器的整体结构如图 ?? 所示。

4.2.2 时序注意力融合模块

多尺度时序编码器输出 $B \times 512 \times 100$ 的时序特征，其时间维度包含 100 个时间步的依赖关系。若仅对时间维做全局平均池化，会忽略时间步之间的顺序与依赖，无法建模“动作前半段与后半段”等长距离时序关系；一维卷积的感受野受限于卷积核大小，对跨越整个序列的依赖建模能力有限。为此，本文引入时序注意力融合模块，采用自注意力机制对时序维度进行建模，使任意两个时间步之间均可直接建立依赖，从而显式捕捉不同时间步之间的关联，同时通过位置编码保留时序顺序信息。采用 100 个时间步的序列长度，是在保留主要时序结构与控制自注意力计算复杂度之间做出的折中。

序列化与位置编码。时序注意力融合模块的输入为 $\mathbf{H} \in \mathbb{R}^{B \times 512 \times 100}$ 。首先将通道维与时间维转置，得到 $\mathbf{H}' \in \mathbb{R}^{B \times 100 \times 512}$ ，即将每个时间步视为序列中的一个 token，共 100 个 token。随后添加位置编码（Positional Encoding），采用 Transformer^{vaswani2017attention}中常用的正弦与余弦函数对位置进行编码。设位置为 $pos \in \{0, \dots, 99\}$ ，维度索引为 i ， $d = 512$ 为特征维度，则位置编码定义为：

$$\text{PE}_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right), \quad \text{PE}_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right) \quad (4-4)$$

式中： pos ——序列位置索引； d ——嵌入维度。

式 (??) 给出的编码使不同位置具有唯一的向量表示，且连续位置之间的编码平滑变化，有利于模型学习时序结构。位置编码与输入相加后经 Dropout（比率 0.1）以增强泛化，得到 $\tilde{\mathbf{H}} \in \mathbb{R}^{B \times 100 \times 512}$ 。

多头自注意力。位置编码后的序列输入多头自注意力层。本文采用 8 个注意力头，每个头的 key/query/value 维度为 $d_k = d_v = 512/8 = 64$ 。对于每个头，自注意力的计算

形式为：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} \right) \mathbf{V} \quad (4-5)$$

式中： $\mathbf{Q}$ 、 $\mathbf{K}$ 、 $\mathbf{V}$ ——查询、键、值矩阵； d_k ——单头注意力维度。

式 (??) 为多头自注意力子层中的单头计算形式。多头注意力的输出经线性投影后与残差相加，再经层归一化，得到与输入同形状的输出 $\mathbf{O} \in \mathbb{R}^{B \times 100 \times 512}$ 。该输出对时间维做全局平均池化，将 $B \times 100 \times 512$ 聚合为 $B \times 512$ 的固定长度嵌入向量 $\mathbf{z}$ 。该向量作为后续双分类器的输入，或作为少样本模式下图注意力的输入特征。时序注意力融合模块的结构如图 ?? 所示。

4.2.3 增强图注意力网络

在少样本类增量学习的增量阶段，每个新类别仅有 1 或少数几个样本，直接使用样本均值作为类别原型容易受噪声影响，且类别之间的相对关系未被显式建模。若将每个类别视为图中的一个节点，则“某类与其它类的相似或排斥关系”可作为边，通过图上的信息传播使原型表示利用上下文进行增强。CEC^{zhang2021cec} 提出通过图注意力网络在分类器层传播类别间的上下文信息，使原型表示能够利用其它类别的信息进行增强。本文在此基础上引入时序关系增强层，对原型特征在送入图注意力之前进行变换，以增强对 Wi-Fi CSI 这类时序模态下动作模式的关系建模能力。该模块主要作用于少样本增量阶段，针对的核心问题是极少样本下原型表示不稳定、类别间关系缺乏显式建模。

时序关系增强。增强图注意力网络在少样本学习模式下工作。设支持集样本经多尺度时序编码与时序注意力融合后得到原型特征 $\mathbf{P} \in \mathbb{R}^{B \times N_{\text{way}} \times 512}$ ，查询集样本得到查询特征 $\mathbf{Q} \in \mathbb{R}^{B \times N_{\text{query}} \times 512}$ 。首先对原型特征进行时序关系增强，通过一个两层全连接网络对 512 维特征进行非线性变换：

$$\tilde{\mathbf{P}} = \text{MLP}(\mathbf{P}) = \mathbf{W}_2 \cdot \sigma(\mathbf{W}_1 \mathbf{P} + \mathbf{b}_1) + \mathbf{b}_2 \quad (4-6)$$

式中： $\tilde{\mathbf{P}}$ ——时序关系增强后的原型特征； $\mathbf{P}$ ——支持集原型张量。

式 (??) 在图传播前对原型做非线性变换。该模块可学习对时序相关模式的强调或抑制，使后续图注意力在更具判别力的原型表示上进行传播。查询特征不经此时序关系增强，直接参与图注意力的信息传播，以保持其原始表示的同时从原型处获取上下文。

图注意力传播。增强后的原型与查询特征在节点维度拼接，得到 $\mathbf{G} \in \mathbb{R}^{B \times (N_{\text{way}} + N_{\text{query}}) \times 512}$ 的联合图，其中每个节点对应一个原型或一个查询样本。采用单头自注意力 ($n_{\text{head}} = 1$) 对该图进行信息传播：

$$[\mathbf{P}', \mathbf{Q}'] = \text{SelfAttn}([\tilde{\mathbf{P}}; \mathbf{Q}]) \quad (4-7)$$

式中： $\mathbf{P}'$ 、 $\mathbf{Q}'$ ——图自注意力更新后的原型与查询特征； $\text{SelfAttn}(\cdot)$ ——与式 (??) 同构

的自注意力。

式 (??) 在联合节点集合上执行一次自注意力消息传递。通过自注意力，原型节点可吸收其它原型与查询的上下文，查询节点也可吸收所有原型的上下文，从而在少样本条件下提升分类决策的鲁棒性。自注意力计算完成后，将输出按原型与查询的数目拆分为 $\mathbf{P}'$ 与 $\mathbf{Q}'$ ，最终通过余弦相似度计算分类 logits:

$$s_{ij} = \tau \cdot \frac{\mathbf{Q}'_i \cdot \mathbf{P}'_j^\top}{\|\mathbf{Q}'_i\|_2 \cdot \|\mathbf{P}'_j\|_2} \quad (4-8)$$

式中: s_{ij} ——查询 i 与原型 j 的余弦相似度 logit; τ ——温度系数。

式 (??) 在图增强特征上建立查询—原型相似度得分。图注意力网络仅在少样本增量阶段 (N-way K-shot 评估及增量会话中更新分类器头并前向计算 logits 时) 参与前向传播; 标准的基础训练与推理阶段则直接使用时序注意力融合后的嵌入接入双分类器, 不经过图注意力, 因而基础会话的端到端分类损失亦不经由该模块回传。增强图注意力网络的结构如图 ?? 所示。

4.2.4 双分类器架构

在少样本类增量学习场景下, 新增类别的样本极少, 若仅使用单一分类器, 容易对少量样本产生类别级过拟合, 导致决策边界过于尖锐、泛化能力不足。CLOM^{zou2022clop} 通过引入双分类器架构, 从不同特征子空间进行预测并加权融合, 缓解了类别级过拟合。本文采用类似设计, 将骨干特征与域内变换特征分别送入主分类器与域内分类器, 再对两者输出进行加权融合, 使预测既依赖骨干的通用表示, 也利用域内子空间的补充信息。

主分类器。设时序注意力融合后的嵌入为 $\mathbf{z} \in \mathbb{R}^{B \times 512}$ 。主分类器直接使用 $\mathbf{z}$ 与分类器权重 $\mathbf{W}_{\text{main}} \in \mathbb{R}^{C \times 512}$ 的余弦相似度作为 logits, 其中 C 为类别总数。具体地, 对 $\mathbf{z}$ 与 $\mathbf{W}_{\text{main}}$ 的行分别做 L2 归一化后计算内积, 再乘以温度系数 τ (本文取 $\tau = 16$) 得到主分类器的 logits:

$$\mathbf{o}_{\text{main}} = \tau \cdot \frac{\mathbf{z} \mathbf{W}_{\text{main}}^\top}{\|\mathbf{z}\|_2 \|\mathbf{W}_{\text{main}}\|_2} \quad (4-9)$$

式中: $\mathbf{o}_{\text{main}}$ ——主分类器 logits; $\mathbf{W}_{\text{main}}$ ——主分类器权重矩阵。

式 (??) 通过归一化内积构造主分类器 logits: τ 较大时 softmax 输出更平滑, 有利于少样本下的泛化。

域内分类器。域内分类器先将 $\mathbf{z}$ 通过可学习的线性变换矩阵 $\mathbf{W}_{\text{id}} \in \mathbb{R}^{512 \times 256}$ 映射为 256 维域内特征, 该矩阵采用 Kaiming 均匀初始化。映射后的特征经批归一化与 LeakyReLU (负斜率 0.1) 激活, 再通过域内分类器权重 $\mathbf{W}_{\text{id-fc}} \in \mathbb{R}^{C \times 256}$ 计算余弦相似度并乘以温度 τ , 得到域内分类器的 logits $\mathbf{o}_{\text{id}}$ 。域内子空间通过线性变换与非线性激活形成与骨干不同的表示, 可捕捉互补的判别信息。

加权融合与动态权重。两个分类器的输出按权重融合:

$$\mathbf{o} = \alpha \cdot \mathbf{o}_{\text{main}} + (1 - \alpha) \cdot \mathbf{o}_{\text{id}} \quad (4-10)$$

式中： α ——主分支融合权重； $\mathbf{o}_{\text{main}}$ 、 $\mathbf{o}_{\text{id}}$ ——主分类器与域内分类器 logits。

式(??)对两支路输出做线性融合。 α 默认取 0.7，即主分类器权重 0.7、域内分类器权重 0.3。在增量学习的早期会话（如 Session 1、2），新类别特征可能尚不稳定，域内子空间因样本过少而估计不准，本文将主分类器权重动态调整为 0.75、域内分类器权重调整为 0.25，以增强对骨干特征的依赖，随会话推进再恢复默认权重。上述维度与融合系数由预实验确定，主实验中固定使用。融合后的 $\mathbf{o}$ 经 softmax 得到各类别的预测概率。双分类器架构如图 ?? 所示。

增量阶段的分类器更新。在增量学习阶段，新类别到达时需更新分类器权重。本文采用基于原型网络^{snell2017prototypical}思想的原型初始化策略，对主分类器与域内分类器分别进行更新。对每个新类别 c ，利用其支持集 S_c 中的样本经编码器提取的特征计算类别原型。当某类有多个样本时，采用加权平均以降低离群点影响：

$$\mathbf{p}_c = \frac{\sum_{i \in S_c} w_i \cdot \mathbf{z}_i}{\sum_{i \in S_c} w_i}, \quad w_i = \frac{1}{1 + \|\mathbf{z}_i - \bar{\mathbf{z}}_c\|_2} \quad (4-11)$$

式中： $\mathbf{p}_c$ ——类别 c 加权原型； w_i ——支持集样本 i 的权重。

式(??)对离群点降权以稳定原型估计。当某类仅有 1 个样本时，直接取该样本的嵌入作为原型。原型计算完成后，对其做 L2 归一化并乘以尺度因子，以恢复与已有类别权重一致的范数：

$$\hat{\mathbf{p}}_c = \min(\|\mathbf{z}\|, \sqrt{d}) \cdot \frac{\mathbf{p}_c}{\|\mathbf{p}_c\|_2} \quad (4-12)$$

式中： $\hat{\mathbf{p}}_c$ ——尺度复位后的类原型（用作分类器权重行）； d ——对应分支特征维度。

式(??)使新类权重与旧类在范数尺度上可比，减轻尺度不一致引起的 logits 偏移。主分类器与域内分类器均按上述方式更新；域内分类器需先将特征经 $\mathbf{W}_{\text{id}}$ 、批归一化与 LeakyReLU 变换后再计算原型。该策略无需在增量阶段对编码器进行微调，避免了因极少样本导致的过拟合，符合 CEC/CLOM 等方法的实践。

4.3 实验方案设计

为验证本文提出的少样本类增量学习方法在 Wi-Fi CSI 动作识别任务上的效果，本节说明实验所采用的数据集划分、实验环境、训练配置、评价指标及对比方法。实验设计遵循 FSCIL 领域的通用设定^{tian2024fscilsurvey}，在 XRF 与 WiAR 两个公开数据集上分别完成主实验与补充数据集验证：XRF 用于验证多类别、较大规模 CSI 时序场景下的方法有效性；WiAR 用于在另一公开 Wi-Fi 动作识别数据上检验所提方法在较小规模与不同 CSI 数据分布下的适用性。两类数据上的训练超参、骨干结构与评价指标保持一致，以保证结果可比。

4.3.1 数据集划分策略

数据集选取。本章在两类公开 Wi-Fi 动作识别数据上开展少样本类增量学习实验。XRF 数据集基于 Wi-Fi CSI 采集，类别数多、样本规模大，适合构造长序列增量会话以重点检验方法在复杂类增量条件下的判别与抗遗忘能力。WiAR 数据集为公开的 Wi-Fi 室内活动识别数据^{guo2019wiar}，共 16 类动作，由 10 名志愿者在多类室内环境下采集，规模相对较小，用于在另一公开 Wi-Fi 动作识别数据集上补充检验所提方法在不同类别规模与不同 CSI 数据分布下的适用性。

(1) XRF 数据集划分。XRF 包含 55 类室内动作，涵盖人一物交互、人一人交互、健身、身体运动与人一机交互等五大类型。每条样本对应 $270 \text{ 维} \times 1000$ 长度的时序特征，由原始 CSI 信号经预处理得到，可直接输入 4.2 节所述的多尺度时序编码器。第三章已对 XRF 与其他 Wi-Fi 室内活动数据集的对比进行了说明（见表 ??），本章沿用该数据集，以保持与类增量学习实验的一致性，便于对比不同增量范式（CIL 与 FSCIL）下的模型表现。此外，XRF 每类动作由 30 名志愿者采集、每人每类贡献约 20 条数据，主体多样性有助于模型学习更具泛化能力的表征，对少样本场景下的泛化尤为重要。

按 4.1 节的 FSCIL 任务定义，将 XRF 划分为 1 个基础会话与 5 个增量会话。基础会话（Session 0）使用前 30 类进行充分训练，每类在训练集上约 14 个样本（7:3 划分）；随后的 5 个增量会话（Session 1-5）每会话引入 5 个新类别，即 5-way 1-shot 设定，每类仅有 1 个训练样本。训练集与测试集按 7:3 划分，该比例在保留足够训练样本与保证测试集代表性的同时，与 XRF 数据集的通用划分方式一致；各会话内样本按固定索引列表划分至训练或验证子集，以保证不同方法在相同样本集合上可比。Session 0 的训练集覆盖类别 1-30，测试集同样为 1-30 类；Session j ($j \geq 1$) 的训练集仅覆盖 $30 + 5(j-1) + 1$ 至 $30 + 5j$ 共 5 个新类，每类 1 个样本，测试集则需在全体已见类别（1 至 $30 + 5j$ 类）上评估，以衡量模型对新老类别的综合判别能力。表 ?? 汇总了各会话的类别范围与训练样本数。数据集划分示意如图 ?? 所示。

与类增量学习的差异。第三章的类增量学习（CIL）设定中，基础任务含 15 类，后续 4 个任务各新增 10 类，且每个增量任务可访问充足的新类样本；记忆回放机制使模型在每个增量阶段仍能接触到旧类代表样本。本章在 XRF 上的 FSCIL 设定则更为苛刻：基础会话 30 类，增量会话 5 类，且每增量会话每类仅有 1 个训练样本；为与 FSCIL 通用协议保持一致，主实验不采用记忆回放。这种差异使得 FSCIL 既要应对样本稀缺，又要应对类别持续扩展带来的表示空间压力，对模型的特征表示与分类器设计提出了更高要求。

(2) WiAR 数据集划分。本文采用 WiAR16 式少样本类增量设置^{guo2019wiar}：共 16 类动作，基础会话（Session 0）包含 6 个基础类并完成充分训练；其后 5 个增量会话依次引入剩余 10 个新类（每会话 2 个新类），各新类在增量侧仍按少样本支持集协议提供监督。各会话训练结束后，模型在截至该会话的全部已见类别测试集上计算全类测试 Top-1 准确率，并据此汇总各 Session 曲线、平均准确率（AA）与末次会话准确率等指

标。WiAR 上的对比实验与 XRF 主实验共用相同的骨干与表 ?? 所列核心训练配置，以保证不同数据集间对照的公平性；两类数据的类别数与划分密度不同，故数值结果仅用于各自数据集内的相对比较，不宜直接横向对比绝对高低。

WiAR 类别规模小于 XRF，因此本文采用 6 个基础类和 5 个增量会话的划分方式，在有限类别数下形成连续递增评估流程，并检验方法在不同 Wi-Fi CSI 数据规模下的适用性。

表 4-2 FSCIL 实验数据划分（XRF，基础 30 类，5-way 1-shot）

会话	类别范围	训练类别数	训练样本数 (每类)	累计类别数	测试类别范围
Session 0（基础）	1-30	30	14	30	1-30
Session 1	31-35	5	1	35	1-35
Session 2	36-40	5	1	40	1-40
Session 3	41-45	5	1	45	1-45
Session 4	46-50	5	1	50	1-50
Session 5	51-55	5	1	55	1-55




图 4-3 XRF 数据集在少样本类增量学习场景下的划分示意

4.3.2 实验环境与训练配置

实验环境。实验在配备 NVIDIA GPU（RTX 3090 或同等级，显存 24 GB）、CUDA 11.x 的服务器上运行，使用 Python 3.9 与 PyTorch 1.13.1 构建并训练模型。数据加载采用 8 路并行子进程读取，以减少 I/O 等待、加速训练。所有对比方法与本文方法均在同一环境下运行，以保证结果可比。为减小随机性影响，主对比实验与关键消融实验均在固定随机种子下重复多次，结果报告其平均值；敏感性分析等补充实验可另行设置重复次数与统计方式，详见各小节。

在 WiAR 少样本类增量实验中，样本首先整理为 90 通道、长度为 512 的 CSI 时序表示。为适配第四章方法中与 XRF 保持一致的时序编码输入形式，实验将其沿通道维

扩展为 270 通道，形成 270×512 的输入张量。该处理仅用于统一模型输入维度，不改变 WiAR 的类别划分与少样本增量协议。

基础训练配置。基础会话（Session 0）采用 SGD 优化器，momentum 0.9、Nesterov 加速，权重衰减 5×10^{-4} 。初始学习率 0.1，学习率在第 60、70 轮各衰减为原值的 0.1 倍（分段衰减策略），使模型在训练中后期以更小步长微调，从而获得更稳定的收敛。训练 100 轮，batch size 为 64，该设置兼顾显存占用与梯度估计稳定性。考虑到本文方法包含多个可训练模块，各模块对学习率的敏感程度不同，实验采用分组学习率：多尺度时序编码器与双分类器使用基础学习率 0.1；时序注意力融合模块使用较小学习率 0.01，因其自注意力结构在较大学习率下易出现不稳定，较小学习率有助于稳定训练。图注意力网络仅在增量阶段的 N-way K-shot 前向中参与计算，基础会话不对该子模块单独设定学习率（见表 ??）。温度参数 $\tau = 16$ ，基础模式与增量模式下主分类器与原型分类均对特征与权重做 L2 归一化后采用余弦相似度作为 logits。该取值与 4.2.4 节双分类器中余弦 logits 的温度尺度一致，系依据少样本分类中常见取值与预实验所定的固定超参；本文实验部分不对 τ 另行扫描，后文仅在基础类别数、支持集规模等设定下讨论敏感性。基础训练结束后，采用各类别训练样本嵌入的均值初始化对应分类器权重，该策略在 FSCIL 领域被广泛采用，可在无额外训练的情况下为增量会话提供合理的分类器初值。

增量学习配置。增量会话（Session 1-5）默认不进行编码器微调，仅根据支持集样本提取特征并更新分类器权重，与 CEC、CLOM 等方法的实践一致。该设置的核心考虑是，1-shot 条件下支持集样本不足以稳定更新深层编码器，若继续反向传播至特征提取部分，模型容易记忆个别样本噪声。因此，增量阶段主要通过原型初始化、图注意力关系传播与分类器更新完成新类接入，以降低少样本过拟合风险。这种“冻结编码器、仅更新分类器”的策略可有效避免因极少样本导致的编码器过拟合，同时减少灾难性遗忘的风险。若需对分类器在支持集上进行少量轮次微调，可将学习率设为 0.001×0.1 ，最大训练轮数 5，并以验证表现早停（容忍 3 轮无提升），以在过拟合前及时停止；本文主实验未采用该微调路径。此外，为考察不同基础类别数对性能的影响，实验在基础类别数分别取 10、15、20、25、30、35 等设定下重复训练（对应每增量会话新类数目不同）；主实验取基础类别数为 30。主要超参数汇总如表 ?? 所示。

4.3.3 评价指标

少样本类增量学习的评估需同时反映“对新类的学习能力”与“对旧类的保持能力”，且推理时模型需在全体已见类别上统一分类，不提供任务或会话标识。实验中采用准确率（Accuracy）、性能下降率（Performance Drop, PD）与平均准确率（Average Accuracy, AA）三类指标^{tian2024fscilsurvey}，与 FSCIL 领域的通用评价方式保持一致。

准确率（Accuracy）。各会话结束后，在全体已见类别的测试集上计算 Top-1 分类准确率。设 Session j 的测试样本数为 N_j ， $y_{\text{pred}}^{(i)}$ 与 $y_{\text{true}}^{(i)}$ 分别为第 i 个样本的预测标签与真实标签，则

表 4-3 少样本类增量学习训练超参数

参数	基础训练 (Session 0)	增量学习 (Session 1-5)
训练轮数	100	0 (仅更新分类器)
学习率 (编码器/分类器)	0.1	—
学习率 (时序注意力)	0.01	—
学习率 (图注意力)	—	—
学习率调度	第 60、70 轮各 $\times 0.1$	—
权重衰减	5×10^{-4}	—
batch size	64	全部样本
温度 τ	16	16
分类模式	余弦相似度 (主分类器 / 原型)	余弦相似度 (原型)

注：增强图注意力网络在 Session 0 的分类主路径中不参与前向计算，表内不对其单独列出基础阶段学习率；该模块在增量会话的 N-way K-shot 前向中参与原型与查询间的关系传播。

$$\mathcal{A}_j = \frac{1}{N_j} \sum_{i=1}^{N_j} \mathbb{I} \left(y_{\text{pred}}^{(i)} = y_{\text{true}}^{(i)} \right) \quad (4-13)$$

式中： $\mathcal{A}_j$ ——会话 j 的全类 Top-1 准确率； $\mathbb{I}(\cdot)$ ——指示函数。

式 (??) 给出会话级准确率的经验估计。随着增量推进，类别数从 30 增至 55，若模型发生灾难性遗忘，旧类准确率会下降；若对新类过拟合不足或分类边界不合理，新类准确率会偏低；二者均会拉低 $\mathcal{A}_j$ 。因此，准确率是衡量稳定性与可塑性平衡的综合指标。

性能下降率 (PD)。用于衡量从基础会话到末会话的准确率下降幅度，反映模型在长序列增量后的遗忘程度。设共有 m 个增量会话，则

$$\text{PD} = \mathcal{A}_0 - \mathcal{A}_m \quad (4-14)$$

式中：PD——性能下降率； $\mathcal{A}_0$ 、 $\mathcal{A}_m$ ——基础会话与末次会话的全类准确率。

式 (??) 刻画基础阶段相对末次会话的整体准确率落差。PD 越大表示遗忘越严重；理想情况下模型在增量过程中保持性能，PD 应接近 0。在少样本设定下，由于每个增量会话的监督信息极少，模型易在适应新类的同时遗忘旧类，PD 通常为正；通过比较不同方法的 PD，可直观判断各方法在缓解遗忘方面的效果。

平均准确率 (AA)。对各会话准确率取平均，用于综合反映模型在整个 FSCIL 过程的表现：

$$\text{AA} = \frac{1}{m+1} \sum_{j=0}^m \mathcal{A}_j \quad (4-15)$$

式中：AA——平均准确率； $\mathcal{A}_j$ ——式 (??) 中的会话准确率。

式 (??) 对各阶段准确率等权平均以度量全过程稳定性。AA 越高表示模型在各阶段均保持较好的识别能力；若某方法在早期会话表现较好但后期急剧下降，其 AA 会受后期低准确率拖累；反之，若方法在整个增量过程中较为稳定，AA 会相对较高。在本

文设置中 $m = 5$ ，即 AA 为 Session 0-5 六个会话准确率的均值。表 ?? 简要概括了上述指标的含义与用途。

表 4-4 FSCIL 评价指标说明

指标	含义	用途
准确率 $\mathcal{A}_j$	Session j 在全体已见类别上的 Top-1 正确率	衡量各阶段综合判别能力
PD	$\mathcal{A}_0 - \mathcal{A}_m$ ，基础会话准确率与末会话准确率之差	衡量遗忘程度
AA	各会话准确率的算术平均	综合衡量整个 FSCIL 过程的表现

4.3.4 对比方法与基线

为比较分析本文方法，实验设置以下对比。**Baseline**：仅使用多尺度时序编码器与全局平均池化，接单分类器，无时序注意力、无图注意力、无双分类器，作为本文方法各模块的消融基准，代表最小可用配置。**CEC^{zhang2021cec}**：采用图注意力网络在分类器层传播类别间上下文信息，通过自注意力使原型与查询在图上交换信息，增强少样本下的类别表示。**iCaRL^{rebuffi2017icarl}**：通过维护 exemplar 集合重放旧类样本，结合基于二元交叉熵的知识蒸馏约束新旧模型输出一致性，推理时采用最近类均值（NCM）分类器，是类增量学习领域的经典方法；将其纳入对比旨在验证 CIL 方法在 FSCIL 场景下的适用性（仅在 XRF 主对比表中报告）。**FACT^{zhou2022fact}**：面向 FSCIL 的前向兼容训练，在基础阶段引入虚拟原型与实例混合等机制，为后续新类预留嵌入空间，增量阶段在固定骨干上扩展分类器；本文依据其公开算法与推荐设置在相同数据划分与表 ?? 所列训练超参下完成复现与测试。**C-FSCIL^{hersche2022cfscil}**：在冻结元学习特征提取器的前提下，结合可训练全连接层与动态外显记忆，以高维原型与对齐损失缓解增量干扰；同样在本文协议下完成复现。**DyCR^{pan2025dyer}**：动态聚类与恢复网络，在增量阶段引入可训练的动态子结构，并通过正交分解将特征划分为上下文图与类别图；上下文图在会话间保留并与类原型结合以恢复旧类样本嵌入，类别图在原型引导下进行距离缩放以强化类内紧凑与类间分离，从而在缓解灾难性遗忘的同时改善新类适配。本文方法：在 CEC 等 FSCIL 方法的基础上，引入面向 Wi-Fi CSI 时序模态的多尺度时序编码与时序注意力融合，并在图注意力中增加时序关系增强层，结合双分类器架构，构成完整的 FSCIL 方案。由于现有 FSCIL 方法多面向视觉图像数据，本文在统一的 Wi-Fi CSI 输入与训练协议下对上述方法进行适配与比较。

表 ?? 汇总了主要对比方法的年份、类型与核心机制，便于与正文实验结果对照阅读。

XRF 主对比实验在表 ?? 所述划分与 5-way 1-shot 协议下进行，各方法共享相同划分、评价指标与软硬件环境。WiAR16 对比实验在 6 个基础类 + 5 个增量会话的划分下进行，对比方法集合为 Baseline、CEC、FACT、C-FSCIL、DyCR 与本文方法，不包含 iCaRL，以避免在极小增量步长设定下引入与主文主线无关的对照分支。除特别说明外，

表 4-5 少样本类增量学习主要对比方法概况

方法	年份	类型	主要机制	文献/备注
Baseline	—	最小配置	多尺度时序编码 + 单分类器	本文构造
CEC	2021	结构型 FSCIL	图注意力演化分类器、上下文传播	CVPR ^{zhang2021cec}
iCaRL	2017	类增量（对照）	Exemplar 回放、蒸馏、NCM	ECCV ^{rebuffi2017icar1} ；仅 XRF
FACT	2022	前向兼容型 FS-CIL	虚拟原型、实例混合、预留嵌入空间	CVPR ^{zhou2022fact}
C-FSCIL	2022	记忆约束型 FS-CIL	高维原型、对齐损失、外显记忆	CVPR ^{hersche2022cfscil}
DyCR	2025	动态恢复型 FS-CIL	正交分解、上下文图恢复旧嵌入、类别图距离缩放	IEEE TNNLS ^{pan2025dyer}
本文方法	—	CSI 时序增强型 FSCIL	多尺度编码、时序注意力、增强图注意力、双分类器	—

两类数据集上的结果均报告各 Session 全类测试准确率、PD 与 AA。

4.4 实验结果与分析

本节依次汇报 XRF 与 WiAR 上的主对比结果，随后给出模块消融、基础类别数与支持集规模等敏感性分析。除特别说明外，XRF 实验采用 4.3.1 节（1）所述划分与 5-way 1-shot 协议；WiAR 实验采用 4.3.1 节（2）所述 WiAR16 划分。评价指标均为各 Session 全类测试准确率、PD 与 AA。

4.4.1 XRF 数据集对比实验结果

主对比。表 ?? 列出了 Baseline、CEC^{zhang2021cec}、iCaRL^{rebuffi2017icar1}、FACT^{zhou2022fact}、C-FSCIL^{hersche2022cfscil}、DyCR^{pan2025dyer} 与本文方法在各 Session 的准确率及 PD、AA。Baseline 仅使用多尺度时序编码器与全局平均池化，接单分类器，代表“最小可用配置”。CEC 通过图注意力网络传播类别间上下文信息。iCaRL 是类增量学习领域的经典方法，依赖 exemplar 重放与知识蒸馏缓解遗忘。FACT、C-FSCIL 与 DyCR 为近年视觉领域具有代表性的 FSCIL 基线：FACT 强调基础阶段前向兼容训练，C-FSCIL 强调显式记忆与约束式原型更新，DyCR 则通过动态可训练子网络与正交分解—上下文恢复机制改善增量阶段的新旧类平衡。本文方法进一步引入多尺度时序编码与时序注意力融合，并增加时序关系增强层与双分类器架构，构成面向 Wi-Fi CSI 时序模态的完整方案。

从第四章主实验结果看，Baseline 在基础会话后缺乏有效的旧类保持机制，随着增量会话推进性能持续下降；相比之下，本文方法虽然在首次增量后也出现一定波动，但后续能够较快恢复并保持相对稳定的识别水平。这说明，时序增强、图关系建模和双分类器融合共同提升了模型在少样本条件下的持续适应能力。以下结合表 ?? 逐项讨论各方法表现。

从表 ?? 可见，iCaRL 在 Session 0 达到 89.94%，基础训练阶段的表现与其他方法接近；然而自 Session 1 起准确率骤降至 7.49%，后续会话持续维持在 5%–7% 的极低水

平, Session 5 仅为 5.13%, PD 高达 84.81 个百分点, AA 仅为 20.19%。iCaRL 的核心机制包括 exemplar 集合重放旧类样本、基于二元交叉熵的知识蒸馏以及最近类均值分类器, 这些机制均依赖充足的训练样本; 在 FSCIL 的 1-shot 设定下, 增量阶段无法访问旧类数据使 exemplar 重放无从实施, 每类仅 1 个样本使蒸馏信号稀疏且类均值原型对噪声敏感, 导致其在增量阶段难以维持有效的分类能力。这一结果表明, 依赖后向补偿机制的 CIL 方法在极少样本条件下难以有效运作。

Baseline 在 Session 0 达到 96.67%, 基础训练阶段的拟合能力较强; 然而自 Session 1 起准确率急剧下降, Session 3 即降至 60.74%, Session 5 仅为 56.06%, PD 高达 40.61 个百分点, AA 为 68.27%, 遗忘较为严重。这表明仅依赖多尺度编码器与单分类器的最小配置在增量阶段难以有效抵御灾难性遗忘。CEC 在 Session 0 为 94.63%, Session 5 为 63.75%, PD 为 30.88, AA 为 74.05%, 较 Baseline 的 PD 降低 9.73 个百分点、AA 提升 5.78 个百分点, 表明图注意力网络通过类别间上下文传播在一定程度上缓解了遗忘, 但在缺乏时序建模与多分类器约束的情况下, 改善幅度仍然有限。

FACT 在 Session 0 为 90.25%, 与本文方法 (90.00%) 接近; Session 1 达到 81.67%, 为表中该会话最高, 说明前向兼容训练在增量初期对新旧类联合判别具有一定优势。但随着会话推进, FACT 的准确率呈总体下降趋势, Session 5 为 61.08%, PD 为 29.17, AA 为 73.19%, 均劣于本文方法 (Session 5 为 74.24%, PD 为 15.76, AA 为 78.48%)。这表明在 Wi-Fi CSI 时序任务上, 仅依赖视觉 FSCIL 中的虚拟原型与空间预留策略, 难以在增量中后期维持与本文相当的稳定性; 多尺度时序编码与图一双分类器协同对长序列类增量更为关键。C-FSCIL 在各会话上均显著偏低: Session 0 仅为 51.38%, Session 5 为 13.17%, PD 为 38.21, AA 为 23.78%。该结果一方面说明原方法强依赖图像元学习预训练与 MANN 式记忆更新, 在 CSI 模态上直接复现时基础特征质量不足会导致后续原型与对齐环节难以收敛; 另一方面也提示: 在将文献方法迁移至非视觉传感器数据时, 需结合模态特点调整骨干与增量更新策略, 而非仅替换输入张量形状。

DyCR^{pan2025dyer} 在 Session 0 为 89.88%, Session 2–4 维持在 74.00%–76.29% 区间, 体现了动态恢复与类别子空间距离缩放对旧类联合判别的支撑; 然而 Session 5 降至 54.33%, PD 为 35.55 个百分点, AA 为 73.80%, 末会话与平均准确率均低于本文方法。结合 DyCR 在视觉任务中的设计动机^{pan2025dyer}, 可将其理解为在 CSI 时序特征上仍主要依赖与图像域相近的嵌入分解与恢复路径, 对子载波一时间联合结构及长序列类增量的针对性不足; 相较之下, 本文面向 CSI 设计的多尺度时序编码、图注意力关系建模与双分类器融合更有利于在 Wi-Fi 少样本增量场景下维持末阶段判别边界。

本文方法在 Session 0 为 90.00%, 略低于 Baseline 与 CEC, 这可能与多模块联合优化带来的训练复杂度有关。但自 Session 3 起, 本文方法表现出较好的增量稳定性: Session 3 为 75.93%, Session 4 为 77.00%, Session 5 为 74.24%, 后三个会话的准确率维持在 74%–77% 区间, 未出现持续下降趋势。PD 仅为 15.76 个百分点, 在所列方法中最低, 较 Baseline 的 40.61 降低 24.85 个百分点, 较 CEC 降低 15.12 个百分点, 较 FACT

降低 13.41 个百分点，较 DyCR 降低 19.79 个百分点；AA 为 78.48%，在所列方法中最高，较 Baseline 提升 10.21 个百分点，较 CEC 提升 4.43 个百分点，较 FACT 提升 5.29 个百分点，较 DyCR 提升 4.68 个百分点。综合来看，iCaRL 在 FSCIL 场景下的表现表明，依赖 exemplar 重放与知识蒸馏的 CIL 方法在极少样本条件下面临较大限制，其对样本规模的依赖可能影响其在 1-shot 设定下的表现。这也说明，在基础阶段优化特征表示与分类器设计，对于 FSCIL 任务可能更为重要。Baseline 的较大遗忘幅度（PD=40.61）表明，简单的增量更新策略在该任务中存在明显不足，也说明有必要针对 FSCIL 场景进行专门设计。从表 ?? 可见，本文方法在该实验设定下的 PD、AA 和末会话准确率均为所列方法中最优（FACT 在 Session 1 的单点准确率除外）。与此同时，Session 3–5 的准确率维持在 74%–77% 区间，说明该方法在增量后期的性能波动相对较小。

表 4-6 XRF 数据集上少样本类增量学习方法对比实验（Top-1 准确率，%）

方法	S0	S1	S2	S3	S4	S5	PD ↓	AA
Baseline	96.67	73.81	63.33	60.74	59.00	56.06	40.61	68.27
CEC(2021) ^{zhang2021cec}	94.63	80.00	66.83	69.76	69.33	63.75	30.88	74.05
iCaRL(2017) ^{rebuffi2017icarl}	89.94	7.49	6.65	6.15	5.78	5.13	84.81	20.19
FACT(2022) ^{zhou2022fact}	90.25	81.67	67.17	70.67	68.33	61.08	29.17	73.19
C-FSCIL(2022) ^{herschel2022cfsil}	51.58	39.33	18.33	11.81	8.67	13.17	38.21	23.78
DyCR(2025) ^{pan2025dyer}	89.88	80.67	74.00	76.29	67.67	54.33	35.55	73.80
本文方法	90.00	79.52	74.17	75.93	77.00	74.24	15.76	78.48

图 ?? 给出各方法在 Session 0–5 的准确率曲线，与表 ?? 中的数值一致。相较表中各会话的离散数值，曲线更直观地呈现增量过程中准确率随会话推进的整体走向，便于从斜率上对比遗忘快慢，并观察中后期是否维持平台或出现反弹。iCaRL 的曲线在 Session 0 后出现明显下降，Session 1 即从 89.94% 降至 7.49%，此后长期维持在较低水平，说明该方法在 FSCIL 场景下遗忘较为严重。这也反映出，依赖 exemplar 重放与蒸馏的传统 CIL 方案在极少样本设定下面临较大挑战。Baseline 的曲线自 Session 1 起急剧下滑，从 96.67% 持续降至 56.06%，呈陡峭的单调递减趋势，与「仅多尺度骨干加单分类头、增量监督极稀」下的快速遗忘相一致。CEC 的曲线同样单调递减，但下降幅度明显小于 Baseline，Session 5 为 63.75%，较 Baseline 高出 7.69 个百分点，表明图注意力的引入有效减缓了遗忘速率。FACT 的曲线在 Session 1 处于较高位置，但后续总体下行，末会话低于本文方法，与前文在 CSI 任务上「前向兼容与空间预留难以在长序列增量中后期维持与本文相当的稳定性」的归纳相一致。C-FSCIL 的曲线全程处于较低水平，与表 ?? 一致。DyCR 的曲线在中段会话维持在相对较高区间，但末段下滑较快，与表中其末会话准确率及 AA 低于本文方法的结论一致。本文方法的曲线在 Session 1 有所下降后，Session 2–4 出现回升（74.17%→75.93%→77.00%），Session 5 略降至 74.24%，是唯一在增量中后期出现明显回升的主流对比配置，与 Baseline 末会话相比高出 18.18 个百分点；其形态与表 ?? 中本文最低的 PD 与最高的 AA 相互印证。从结果上看，该回升可能与增量类别增多、图注意力在原型与查询联合建模上获得更充

分的类间上下文有关，机制细节仍待结合训练过程进一步分析；双分类器从不同子空间融合预测，亦有助于在类别数增多时降低单一路径决策风险，并在一定程度上平滑单一分类器的过拟合。




图 4-4 XRF 数据集上少样本类增量学习各会话准确率对比

从机制角度归纳，CEC、FACT、C-FSCIL 等面向自然图像的 FSCIL 方法在迁移至 Wi-Fi CSI 时序输入时，往往更依赖图像域中较为成熟的预训练与原型更新假设；当骨干与增量协议改为 CSI 序列时，原型稳定性与时序建模不足的问题会更为突出。DyCR^{pan2025dyer} 等近年方法通过动态子网络与嵌入分解改善新旧类平衡，但其典型设计仍以视觉特征统计为主，直接迁移到子载波一时间联合结构时，仍可能受模态差异影响。相较之下，本文以多尺度时序编码与注意力融合强化 CSI 动作模式提取，并在增量阶段结合图关系传播与双分类器融合，使少样本监督下的决策在统一协议内获得更平滑的更新路径。上述解释用于辅助理解表 ?? 与图 ?? 中的相对优劣，并不构成对其方法实现细节的完整复现结论。

4.4.2 WiAR 数据集对比实验结果

表 ?? 给出了 WiAR16 设置下各方法在 Session 0–5 的全类测试准确率及 AA。与 XRF 主实验相比，WiAR 类别总数较少、增量步长更细，故各 Session 绝对数值不宜与表 ?? 直接横向比较，仅在 WiAR 协议内部考察相对优劣。

表 4-7 WiAR 数据集上少样本类增量学习对比实验（全类测试准确率，%）

方法	S0	S1	S2	S3	S4	S5	AA
Baseline	100.00	87.50	67.78	62.04	54.76	49.31	70.20
CEC(2021) ^{zhang2021cec}	94.44	77.78	65.56	64.82	61.11	54.17	69.80
FACT(2022) ^{zhou2022fact}	98.15	77.78	65.56	81.00	49.23	42.00	69.00
C-FSCIL(2022) ^{hersche2022fscil}	94.44	19.44	10.00	4.50	23.73	11.32	16.70
DyCR(2025) ^{pan2025dyer}	98.15	84.72	68.89	82.00	55.50	47.05	72.72
本文方法	96.30	87.50	72.22	69.44	64.29	61.81	75.30




图 4-5 WiAR 数据集上少样本类增量学习各会话准确率对比

由图 ?? 与表 ?? 可见，本文方法在 AA (75.30%) 与末次会话准确率 (61.81%) 上均优于其余对照，表明在较小规模公开数据集上仍能保持较稳定的新旧类平衡。Baseline 在 Session 0 达到 100%，高于本文方法的 96.30%，但随增量推进下降更为明显，末会话仅为 49.31%，遗忘幅度较大。DyCR 在 Session 3 达到 82.00%，高于本文方法同期 69.44%，说明动态恢复机制在部分中段会话上能够较快适配新类分布；然而其 Session 5 降至 47.05%，较本文方法低 14.76 个百分点，AA 亦低于本文方法 2.58 个百分点，表明在 WiAR 的细粒度增量序列上，末阶段稳定性仍不足。CEC 与 FACT 的 AA 分别停留在 69.80% 与 69.00%，末会话亦明显低于本文方法；C-FSCIL 在 WiAR 上整体偏低，与在 XRF 上的现象一致，提示强依赖原视觉设定记忆与对齐机制的方法在 CSI 模态上迁移难度较大。综合 XRF 与 WiAR 两组结果，本文方法并非仅对单一数据集有效，且在各自协议下于不同规模与划分密度的 Wi-Fi 动作识别数据上均表现出一定稳定性与适用性。

在 WiAR16 这一类别总数较少、增量步长更细的协议下，各方法对「少样本 + 多会话」叠加扰动更为敏感：Baseline 与部分对照在中后段出现较大幅度下滑，与仅依赖单一路径的时序表征、缺乏稳定原型更新支撑有关；本文方法通过多尺度时序与注意力融合提升 CSI 片段可分性，并在增量阶段借助图关系与双分类器融合平滑决策，因而在 AA 与末会话上仍能保持相对优势。该段讨论用于解释表 ?? 与图 ?? 的相对走势，并不引申为跨环境或跨用户的普适结论。

与第三章类增量学习的并列说明。第三章的类增量学习在记忆回放与蒸馏巩固下，于 XRF 末阶段 (Session 4) 整体准确率约为 73.57% (见表 ??)，并于 WiAR-16 设置下给出表 ?? 所列结果；本章 FSCIL 在不可回放旧类数据、增量每类仅 1 样本的条件下，本文方法于 XRF 上 Session 5 为 74.24%，于 WiAR 上 Session 5 为 61.81%。两类设定在基础类数、增量步长与是否重放方面均不一致，故上述数值仅作并列展示，不用于判断

何者「更易」。FSCIL 更强调在极少监督下维持旧类判别边界，与 CIL 中「回放 + 扩展 + 巩固」的技术路线互为补充。

4.4.3 消融实验

为验证各模块的贡献，本节采用逐模块叠加的消融策略：从 Baseline（仅多尺度编码器、全局池化与单分类器）出发，依次叠加时序注意力融合、增强图注意力与双分类器，得到若干消融配置。除模块组合及分阶段引入所必需的阶段性训练安排外，默认学习率、批大小、数据划分与评价协议与主实验保持一致，以便在本节各配置之间进行相对比较。需要说明的是，消融在 Baseline 基础会话收敛后，按上述顺序在已有网络上逐步引入新模块并继续训练；主实验中的本文全文方法（表 ??）则为各模块自始参与端到端的独立训练，二者优化轨迹不同，数值不宜直接等同。本节表格仅反映本文内部模块组合的差异。表 ?? 汇总了各变体的准确率及 PD、AA。

表 4-8 消融实验：各模块配置下的准确率（%）

多尺度 编码	时序注 意力	图注 意力	双分类 器	S0	S1	S2	S3	S4	S5	PD ↓	AA
☐				96.67	73.81	63.33	60.74	59.00	56.06	40.61	68.27
☐	☐			87.78	75.71	66.25	58.89	60.67	59.09	28.69	68.07
☐	☐	☐		90.56	79.05	69.17	61.48	63.00	60.00	30.56	70.54
☐	☐	☐	☐	92.78	80.48	70.42	71.85	71.33	67.88	24.90	75.79

各配置在增量过程中的准确率曲线见图 ??，以下结合表 ?? 对各模块逐一讨论。




图 4-6 消融实验各配置准确率对比

时序注意力模块。在 Baseline 基础上添加时序注意力融合后，Session 0 从 96.67% 降至 87.78%，下降 8.89 个百分点，表明自注意力结构引入的额外参数使基础训练阶段的收敛不如简单全局池化充分。然而在增量阶段，时序注意力表现出较明显的抗遗忘改善：Session 5 从 56.06% 提升至 59.09%，提升 3.03 个百分点；PD 从 40.61 大幅降至

28.69, 改善 11.92 个百分点。AA 基本持平 (68.27%→68.07%), 整体 AA 几乎不变主要受 Session 0 下降的拖累。该结果说明, 时序注意力通过对 100 个时间步进行自注意力建模, 能够捕获更具判别性的时序模式, 使特征表示在新类持续引入时更加稳健, 有效缓解了 Baseline 中严重的灾难性遗忘。Session 0 的下降说明引入该模块后基础训练难度有所增加, 可能与自注意力结构带来的优化复杂度提升有关。

图注意力模块。在“Baseline + 时序注意力”基础上添加图注意力后, Session 0 回升至 90.56%, Session 5 为 60.00%, AA 为 70.54%, 较“+ 时序注意力”提升 2.47 个百分点。图注意力在少样本增量阶段参与前向传播, 使原型与查询通过自注意力交换上下文, 有助于在类别增多时稳定决策边界。与 Baseline 相比, 时序注意力与图注意力的组合将 PD 从 40.61 降至 30.56, 降低 10.05 个百分点, Session 5 从 56.06% 提升至 60.00%, 提升 3.94 个百分点, 表明两个模块的组合在抗遗忘方面已取得明显进展。当前顺序添加的结果同时表明: 图注意力在时序注意力基础上带来约 0.9 个百分点的 Session 5 提升 (59.09%→60.00%), AA 提升 2.47 个百分点 (68.07%→70.54%), 且 Session 3-5 的下降更为平缓。

双分类器模块。在“+ 图注意力”基础上添加双分类器后, Session 5 从 60.00% 升至 67.88%, 提升 7.88 个百分点; PD 从 30.56 降至 24.90, AA 从 70.54 升至 75.79, 提升 5.25 个百分点。双分类器通过主分类器与域内分类器的加权融合缓解类别级过拟合, 在少样本场景下对新类别分类器权重的估计更具鲁棒性。从各 Session 的走势看, 添加双分类器后 Session 3-5 的准确率明显抬升 (61.48%→71.85%, 63.00%→71.33%, 60.00%→67.88%), 说明在增量中后期类别数较多时, 双分类器的收益最为明显。这与 4.2.4 节的分析一致: 单一分类器易对 1-shot 原型过拟合, 决策边界过于尖锐; 双分类器从不同特征子空间进行预测并融合, 平滑了决策边界, 提升了泛化能力。

模块协同效应。综合表 ??, 各模块的逐步添加呈现出清晰的递进式改善。时序注意力单独添加时, 虽使 Session 0 下降 (96.67%→87.78%), 但显著改善了增量稳定性: Session 5 从 56.06% 提升至 59.09%, PD 从 40.61 大幅降至 28.69, 降低 11.92 个百分点。图注意力在时序注意力基础上进一步带来约 2.5 个百分点的 AA 提升。双分类器带来约 5.2 个百分点的 AA 提升, 在当前消融顺序下是单步收益最大的模块。Full 配置 (时序 + 图 + 双分类器) 的 AA 为 75.79%, 较 Baseline (68.27%) 大幅提升 7.52 个百分点; Session 5 为 67.88%, 较 Baseline (56.06%) 提升 11.82 个百分点; PD 为 24.90, 较 Baseline (40.61) 降低 15.71 个百分点。上述结果表明, 三个模块的逐步叠加在增量稳定性方面带来了较明显的改善, Full 配置在所有指标上均优于 Baseline。主实验的本文方法 (Session 0 为 90.00%, Session 5 为 74.24%, AA 为 78.48%) 优于消融表中的 Full 变体, 表明在完整的端到端训练配置下, 各模块之间的协同优化能够更充分地发挥作用。

4.4.4 基础类别数敏感性

在上述模块消融的基础上,进一步考察数据划分中基础类别数对性能的影响。在总类别数固定为 55 的前提下,增大基础会话类别数会减小每个增量会话引入的新类数目;记基础类别数为 B ,则每会话新类数为 $(55 - B)/5$ 。为考察该划分对性能的影响,实验在 $B \in \{10, 15, 20, 25, 30, 35\}$ 下运行本文完整模型,其中 $B = 35$ 时每会话新类数为 4,即在保持 1 个基础会话与 5 个增量会话结构不变的情况下,与表 ?? 主设定相比进一步增大基础阶段监督份额。表 ?? 汇总了 Session 0、Session 5、PD 与 AA。该组实验仅针对本文完整方法;FACT、C-FSCIL 等基线未再系统扫描基础类别数,以避免正文篇幅过度膨胀,主对比仍以表 ?? 为准。

从表 ?? 可见,随 B 从 10 增至 30,AA 从 47.70% 提升至 78.48%,PD 从 69.39 降至 15.76,改善显著。 $B = 10$ 时基础阶段仅覆盖 10 类,骨干难以建立足够判别性的表示,且每增量会话需融入 9 个新类,遗忘最为严重。 $B = 20$ 时 Session 0 虽高,但 Session 5 仅 36.06%,说明基础阶段表现与增量可塑性之间仍需折中。 $B = 35$ 时 Session 5 为 66.36%,AA 为 74.84%,均低于 $B = 30$,表明在总类别数固定时并非基础类越多越好:过度挤占增量阶段的每步新类容量,反而可能削弱末会话上的整体判别。 $B = 30$ 、每会话 5 个新类的划分在本文实验中最为均衡,故作为主实验配置。

表 4-9 不同基础类别数配置下的性能 (%)

基础类别数 B	每会话新类数	S0	S5	PD ↓	AA	备注
10	9	96.67	27.27	69.39	47.70	基础类最少,遗忘最严重
15	8	92.22	31.21	61.01	48.51	—
20	7	97.50	36.06	61.44	56.07	—
25	6	86.67	48.49	38.18	63.44	—
30	5	90.00	74.24	15.76	78.48	主实验配置
35	4	84.76	66.36	18.40	74.84	基础 35 类,每会话 4 个新类

4.4.5 支持集规模对增量性能的影响

表 ?? 所示主实验在增量阶段采用 5-way 1-shot,即每新类仅 1 个训练样本。为观察在保持其余训练与评测协议不变的前提下,适当增加每类支持样本对性能的影响,在温度 $\tau = 16$ 下另行构造每类 3 个与 5 个支持样本的数据组织,并与主实验的 1-shot 设置并列比较。表 ?? 给出 Session 0、Session 5、PD 与 AA。

支持集规模变化对模型表现具有直接影响。由表 ?? 可见,在本文冻结骨干、分类器侧更新及不同支持集构造方式下,末会话准确率与平均准确率等指标并未随支持样本数增加呈简单单调改善:3-shot 与 5-shot 在 Session 5、PD 与 AA 上与 1-shot 主设定互有高低,说明多样本带来的统计稳定性与优化噪声、episode 采样差异之间仍存在折中。尽管如此,本文方法在 1-shot 主设定下仍取得较优的 Session 5 与 PD、AA,表明其并不完全依赖增大支持集规模来获得增益,在极少样本条件下仍具备较好的稳定性。

综合而言，主文仍以 1-shot 作为与 FSCIL 典型设定一致的报告主线；表 ?? 中的 FACT、C-FSCIL、DyCR 等亦在 1-shot 协议下报告，便于与主行结果直接对照。

表 4-10 不同每类支持样本数设定下的性能（本文完整方法， $\tau = 16$ ，%）

每类支持样本数	S0	S5	PD ↓	AA	说明
1（主实验）	90.00	74.24	15.76	78.48	与表 ?? 一致
3	90.56	71.52	19.04	77.14	另行构造支持集并独立训练
5	90.56	72.42	18.13	78.50	另行构造支持集并独立训练

4.5 本章小结

本章面向新增类样本极少的 Wi-Fi CSI 少样本类增量动作识别场景，提出了基于时序增强与图注意力的学习方法。该方法通过多尺度时序编码和时序注意力融合增强 CSI 动作表征，在增量阶段利用增强图注意力网络建模类别原型关系，并结合双分类器架构缓解新旧类偏置和类别级过拟合。实验结果表明，在 XRF 的 5-way 1-shot 设置下，本文方法末次会话准确率达到 74.24%，性能下降率为 15.76 个百分点，平均准确率为 78.48%；在 WiAR16 设置下，末次会话准确率和平均准确率分别为 61.81% 和 75.30%。与 CEC、FACT、C-FSCIL、DyCR 等方法相比，本文方法在两类数据集上均表现出较好的综合性能。消融实验进一步表明，各核心模块均对少样本增量稳定性具有积极作用。

5 结论与展望

本文围绕 Wi-Fi CSI 室内动作识别中类别集合持续扩展的问题展开研究，分别针对新增类别样本相对充足的类增量学习场景和新增类别样本极少的少样本类增量学习场景开展方法设计与实验验证。全文从任务定义、模型构建和实验分析三个层面出发，重点讨论在旧类数据难以完整保留、新类样本数量受限以及 CSI 时序特征易受环境扰动和类别相似性影响的条件下，如何提升 Wi-Fi 感知模型的持续更新能力。基于前文研究内容，本章对全文主要结论进行归纳，并进一步说明后续可完善的研究方向。

5.1 结论

(1) 研究对象与任务界定。本文讨论的并非固定类别集合下的一次性离线训练与识别，而是面向类别持续扩展条件下的 Wi-Fi CSI 室内动作识别：模型需在类别集合随应用逐步扩大的前提下完成更新，并在测试阶段对截至当前的全部已见类别统一判别。围绕上述目标，本文将问题划分为类增量学习与少样本类增量学习两类典型情形，前者对应新增类样本相对充足、可通过记忆库等方式保留旧类信息的设定，后者对应增量阶段每类仅有极少标注、旧类原始训练数据往往难以完整依赖的设定；两类情形体现了从「样本相对充足」到「样本极度稀缺」的递进关系，也为后续方法设计提供了不同的约束界面。

(2) 第三章类增量学习方法与实验结论。针对新增类样本相对充足的类增量学习场景，本文提出回放—扩展—巩固框架：通过基于类均值的代表样本选取构建记忆库并完成旧类回放；在冻结 CSI 特征提取骨干的前提下扩展分类器以接入新类别，减弱新类梯度对旧类表征空间的直接破坏；进而采用教师—学生结构与双边知识蒸馏将扩展阶段积累的新旧类知识巩固回单一主干，并结合平衡微调与分类器重训练等环节缓解增量阶段的新旧类样本不平衡。在 XRF 与 WiAR 两个 Wi-Fi CSI 动作识别数据集上的实验表明，该框架在多阶段类别扩展过程中能够缓解灾难性遗忘并保持较好的增量稳定性：在 XRF 上末次增量阶段准确率达到 73.57%；在 WiAR-16 类增量设置下，平均准确率达到 77.33%，末次阶段准确率达到 64.58%。上述结果表明，在可保留有限旧类代表样本的条件下，通过回放、扩展与巩固的衔接，能够在持续接入新类的同时维持整体判别能力。

(3) 第四章少样本类增量学习方法与实验结论。针对新增类样本极少的少样本类增量学习场景，本文提出基于时序增强与图注意力的学习方法：利用多尺度时序编码器与时序注意力融合模块强化 CSI 动作序列的时序表征；在增量阶段通过增强图注意力网络建模类别原型之间的关系；并采用双分类器架构融合不同来源的判别信息，以缓解新旧类 logits 偏置与类别级过拟合。在 XRF 的 5-way 1-shot 设定下，本文方法末次增量会话准确率达到 74.24%，平均准确率达到 78.48%；在 WiAR 数据集上平均准确率

为 75.30%，末次会话准确率为 61.81%。这表明在增量监督极为稀疏、难以依赖旧类原始数据的条件下，结合 CSI 时序特性进行表征增强与类别关系建模，仍有助于提升新类适应能力并维持对旧类的判别。

（4）两项研究的递进关系与总体认识。第三章与第四章并非简单并列：第三章侧重于在新增类样本相对充足时，如何在旧类保持与新类接入之间取得平衡并完成跨阶段知识整合；第四章进一步面向新增类样本极少的情形，强调通过时序表征增强与类别关系传播改善原型估计与决策边界。二者共同构成面向 Wi-Fi CSI 动作识别持续更新的一条研究路径。总体认识在于：该类任务除了要抑制灾难性遗忘外，还需结合 CSI 时序结构、类别相似性以及样本规模约束进行针对性设计，单一照搬视觉领域增量设定难以充分刻画无线感知场景下的实际困难。

5.2 展望

在本文实验设定下，方法在 XRF、WiAR 等数据集上取得了与对照相比更为稳健的表现，但验证场景仍以固定环境与给定划分为前提，尚未系统覆盖部署环境中的全部变异来源。Wi-Fi CSI 易受房间布局、设备位置与朝向、人员体型与动作习惯以及环境噪声等因素影响，信号分布偏移可能削弱增量阶段的判别边界。在本文工作的基础上，未来可进一步结合域适应、域泛化、元学习或自监督预训练等思路，提升模型在跨环境、跨设备与跨用户条件下的稳健性，并在更严格的跨域协议下开展验证。

第三章框架依赖记忆库存储旧类代表样本以支撑回放与蒸馏，能够在既定存储预算内缓解遗忘；但随着类别数目持续增长，存储占用与隐私合规成本仍可能成为部署瓶颈，也可能限制在敏感场景下的适用性。其原因在于 exemplar 级回放直接保留了原始样本信息。未来可在本文路线之上探索特征级回放、生成式回放、原型约束、参数正则化或无样本蒸馏等机制，在降低对旧类原始样本依赖的同时维持增量阶段的稳定性。

本文主要在离线实验环境中完成模型训练与阶段性评估，而实际 Wi-Fi 感知系统常部署于资源受限的边缘节点，并对延迟与能耗敏感，难以完全复现实验室的批量训练节奏。该局限来自当前研究重心在于方法有效性与可复现对比，而非端到端系统工程。未来可结合模型压缩、参数高效微调、流式数据接入与在线增量更新等手段，在保持增量性能的前提下降低计算与存储开销，使方法更贴近长期在线运行的应用场景。

致 谢

论文写完，也意味着研究生阶段快要结束了。回顾这段时间，从确定选题到查阅资料，从方法设计到实验实现，再到后面的论文撰写和反复修改，整个过程并不轻松。中间遇到过很多具体问题，也走过一些弯路。能够比较顺利地完成这篇论文，离不开很多老师、同学和家人的帮助与支持。

首先，我要感谢我的导师王飞副教授。在论文研究和写作过程中，导师在选题确定、思路梳理、实验设计以及论文修改等方面都给予了我很多指导。每当我在方法理解、实验结果分析或者论文表达上遇到问题时，导师都会耐心指出关键问题，并给出明确的修改建议。导师严谨认真的治学态度和踏实负责的工作方式，也让我在这个过程中学到了很多，这些不仅体现在论文完成上，也会对我之后的学习和工作产生影响。

同时，感谢课题组的老师和同学们在整个研究过程中的帮助。平时在实验、代码、论文写作等方面，大家都给过我很多有价值的建议。很多问题其实都是在不断交流和讨论中逐步理清的。和大家一起学习、讨论和推进工作，也让我在研究生阶段收获了很多。

感谢学校和学院提供的学习与科研环境，也感谢研究生阶段各位任课老师的培养。课程学习和日常训练为我后续开展论文工作打下了基础，也让我对本专业的相关知识有了更系统的理解。

最后，感谢我的家人。感谢你们一直以来对我的理解和支持。在论文写作和实验推进比较紧张的时候，正是因为有你们的鼓励和陪伴，我才能够更加安心地完成研究生阶段的学习任务，并坚持把这篇论文完成下来。

在此，向所有在我研究生阶段给予帮助和支持的老师、同学和家人表示衷心的感谢。

答辩委员会会议决议

答辩委员会表决，一致同意通过论文答辩，并建议授罗弘林软件工程专业工程硕士学位。

常规评阅人名单

本学位论文共接受 7 位专家评阅，其中常规评阅人 5 名，名单如下：

朱利	教授	西安交通大学
徐亦飞	副教授	西安交通大学

学位论文独创性声明 (1)

本人声明：所呈交的学位论文系在导师指导下本人独立完成的研究成果。文中依法引用他人的成果，均已做出明确标注或得到许可。论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 交回学校授予的学位证书；
2. 学校可在相关媒体上对作者本人的行为进行通报；
3. 本人按照学校规定的方式，对因不当取得学位给学校造成的名誉损害，进行公开道歉。
4. 本人负责因论文成果不实产生的法律纠纷。

论文作者（签名）： 日期： 年 月 日

学位论文独创性声明 (2)

本人声明：研究生_____所提交的本篇学位论文已经本人审阅，确系在本人指导下由该生独立完成的研究成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 学校可在相关媒体上对本人的失察行为进行通报；
2. 本人按照学校规定的方式，对因失察给学校造成的名誉损害，进行公开道歉。
3. 本人接受学校按照有关规定做出的任何处理。

指导教师（签名）：_____ 日期：_____ 年 _____ 月 _____ 日

学位论文知识产权权属声明

我们声明，我们提交的学位论文及相关的职务作品，知识产权归属学校。学校享有以任何方式发表、复制、公开阅览、借阅以及申请专利等权利。学位论文作者离校后，或学位论文导师因故离校后，发表或使用学位论文或与该论文直接相关的学术论文或成果时，署名单位仍然为西安交通大学。

论文作者（签名）： 日期： 年 月 日

指导教师（签名）： 日期： 年 月 日

(本声明的版权归西安交通大学所有, 未经许可, 任何单位及任何个人不得擅自使用)